Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

II appello di Statistica per Ingegneria Fisica
21 Luglio 2022

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Esercizio 1. Ajeje Brazorf è un personaggio ben noto ai controllori dell'Azienda Trasporti Milanesi (ATM), perché ogni volta che sale su un tram lo fa regolarmente senza pagare il biglietto. Il numero di multe che Ajeje prende in un mese qualunque è una variabile aleatoria X discreta con la densità di probabilità seguente:

$$p(k) = \frac{1}{\mathrm{e}\, k!} \quad \text{con } k \in \mathbb{N} = \{0, 1, 2, 3 \ldots\}$$

($\mathrm{e} = 2.718\ldots$ è la costante di Nepero). Inoltre, il costo di una multa è fisso e sempre uguale a 37 €.

(a) Calcolate il valore atteso e la varianza del costo complessivo di tutte le multe che Ajeje prende in un mese.

(b) Calcolate la probabilità che in un mese Ajeje prenda complessivamente più di 50 € di multe.

È anche noto che in mesi diversi Ajeje prende sempre multe indipendenti fra loro.

(c) Calcolate la probabilità che nel corso dei prossimi due mesi Ajeje:

  (i) non prenda mai neanche una multa;
  (ii) prenda complessivamente più di 100 € di multe.

Un abbonamento annuale ATM costa 330 €.

(d) Usando un'opportuna approssimazione, calcolate la probabilità che Ajeje abbia convenienza ad abbonarsi anziché continuare a viaggiare senza biglietto per tutta la durata del prossimo anno ($= 12$ mesi).

(e) Quanto potrebbe costare al massimo l'abbonamento annuale, senza far scendere la probabilità del punto precedente al di sotto del 50%?

SOLUZIONE.

(a) La densità assegnata è la densità di Poisson con parametro $\lambda = 1$, per la quale sul formulario troviamo che $\mathbb{E}(X) = \mathrm{Var}(X) = \lambda = 1$. D'altra parte, il costo complessivo di tutte le multe che Ajeje prende in un mese è la variabile aleatoria $Y = 37\,X$. Dalle usuali proprietà del valore atteso e della varianza, troviamo quindi che

$$\mathbb{E}(Y) = \mathbb{E}(37\,X) = 37 \cdot \mathbb{E}(X) = 37 \cdot 1 = 37\,,$$
$$\mathrm{Var}(Y) = \mathrm{Var}(37\,X) = 37^2\,\mathrm{Var}(X) = 37^2 \cdot 1 = 1369\,.$$

(b) La probabilità richiesta è

$$\mathbb{P}(Y > 50) = \mathbb{P}(37\,X > 50) = \mathbb{P}\left(X > \frac{50}{37}\right) = 1 - \mathbb{P}\left(X \le \frac{50}{37}\right) = 1 - \sum_{\substack{k \in \mathbb{N} \text{ t.c.} \\ k \le \frac{50}{37}}} p_X(k)$$
$$= 1 - \sum_{k \in \{0,1\}} \frac{1}{\mathrm{e}\, k!} = 1 - \frac{1}{e}(1+1) = 26.4241\%\,.$$

(c) (i) Sia Z la varibile aleatoria che conta per quanti dei prossimi due mesi Ajeje non prenderà neanche una multa. Abbiamo $Z \sim B(n,q)$ con $n = 2$ prove e con probabilità $q = \mathbb{P}(X = 0) = \mathrm{e}^{-1}$ di successo in ciascuna prova. La probabilità cercata è quindi

$$\mathbb{P}(Z = 2) = p_Z(2) = \binom{n}{2} q^2 (1-q)^{n-2} = \binom{2}{2} \left(\mathrm{e}^{-1}\right)^2 \left(1 - \mathrm{e}^{-1}\right)^{2-2} = \mathrm{e}^{-2} = 13.5335\% \,.$$

(ii) Sia T la varibile aleatoria che conta il numero complessivo di multe che Ajeje prenderà nei prossimi due mesi. Abbiamo $T = X_1 + X_2$, dove X_1 e X_2 sono rispettivamente le multe che prenderà nel primo e nel secondo mese. Poiché X_1 e X_2 sono indipendenti e $X_i \sim \mathcal{P}(1)$ per $i = 1, 2$, segue che anche $T \sim \mathcal{P}(1+1) = \mathcal{P}(2)$ per la proprietà di riproducibilità della densità poissoniana. La probabilità richiesta è dunque

$$\mathbb{P}(37\,T > 100) = \mathbb{P}\left(T > \frac{100}{37}\right) = 1 - \mathbb{P}\left(T \leq \frac{100}{37}\right) = 1 - \sum_{\substack{k \in \mathbb{N} \text{ t.c.} \\ k \leq \frac{100}{37}}} p_T(k) = 1 - \sum_{k \in \{0,1,2\}} \mathrm{e}^{-2} \frac{2^k}{k!}$$

$$= 1 - \mathrm{e}^{-2}(1 + 2 + 2) = 32.3324\% \,.$$

Si noti che la probabilità del punto (i) si poteva calcolare anche così:

$$\mathbb{P}(T = 0) = p_T(0) = \mathrm{e}^{-2} \frac{2^0}{0!} = \mathrm{e}^{-2} \,.$$

(d) Sia $U = X_1 + X_2 + \ldots + X_{12}$ la varibile aleatoria che conta il numero complessivo di multe che Ajeje prenderà nel prossimo anno. Per tale variabile, vale l'uguaglianza di eventi

$$\text{“Ajeje ha convenienza ad abbonarsi”} = \text{“}37\,U > 330\text{”} \,.$$

Come nella risposta precedente, abbiamo $U \sim \mathcal{P}(12 \cdot 1) = \mathcal{P}(12)$, ma, poiché $12 > 5$, ora possiamo usare l'approssimazione gaussiana della densità poissoniana $\mathcal{P}(12) \approx N(12, 12)$. La probabilità desiderata si ricava perciò come segue:

$$\mathbb{P}(37\,U > 330) = \mathbb{P}\left(U > \frac{330}{37}\right) = \mathbb{P}(U \geq 9) = \mathbb{P}(U \geq 8.5) = \mathbb{P}\Bigg(\underbrace{\frac{U - \mathbb{E}(U)}{\sqrt{\mathrm{Var}(U)}}}_{\approx N(0,1)} \geq \frac{8.5 - 12}{\sqrt{12}}\Bigg)$$

$$\simeq 1 - \Phi\left(\frac{8.5 - 12}{\sqrt{12}}\right) \simeq 1 - \Phi(-1.010) = \Phi(1.010) = 84.375\% \,.$$

Nei passaggi precedenti, abbiamo tenuto conto del fatto che U può prendere solo valori interi e usato quindi la correzione di continuità nel modo corretto. Senza la correzione di continuità,

$$\mathbb{P}(37\,U > 330) = \ldots = \mathbb{P}(U \geq 9) = \ldots \simeq 1 - \Phi\left(\frac{9 - 12}{\sqrt{12}}\right) = \ldots = \Phi(0.866) = \frac{0.80511 + 0.80785}{2}$$

$$= 80.648\% \,.$$

(e) Se l'abbonamento annuale costa x anziché 330 €, la probabilità del punto precedente diventa

$$\mathbb{P}(37\,U > x) = \mathbb{P}\left(U > \frac{x}{37}\right) = \ldots \simeq 1 - \Phi\left(\frac{\frac{x}{37} - 12}{\sqrt{12}}\right) .$$

Richiedere che tale probabilità non sia al di sotto del 50% equivale a imporre la disuguaglianza

$$1 - \Phi\left(\frac{\frac{x}{37} - 12}{\sqrt{12}}\right) \geq 0.50 \quad \Leftrightarrow \quad \Phi\left(\frac{\frac{x}{37} - 12}{\sqrt{12}}\right) \leq 0.50 \quad \Leftrightarrow \quad \frac{\frac{x}{37} - 12}{\sqrt{12}} \leq z_{0.50} = 0 \quad \Leftrightarrow \quad x \leq 444 \,.$$

In altre parole, il costo massimo richiesto è 444 €.

Esercizio 2. Il signor Anselmo sta esaminando una vecchia scatola di piastrelle che ha trovato in cantina. Le piastrelle nella scatola sono rettangolari e tutte identiche fra loro. Anselmo non conosce però le dimensioni a e b dei loro lati, e purtroppo non ha con sé un metro per misurarle. Per ricavare almeno una stima della superficie delle piastrelle, Anselmo escogita dunque uno stratagemma: traccia il contorno di una piastrella su un foglio A4, facendo combaciare due margini del foglio con quelli della piastrella. Poi disegna sul foglio 60 punti a caso, in modo che le distanze X e Y (in cm) di ciascun punto dai rispettivi margini siano due variabili aleatorie indipendenti e con densità uniforme continua $X \sim \mathcal{U}(0, 29.7)$ e $Y \sim \mathcal{U}(0, 21)$, dove 29.7 cm e 21 cm sono le dimensioni note del foglio A4. La Figura 1 illustra l'esperimento di Anselmo col suo risultato.

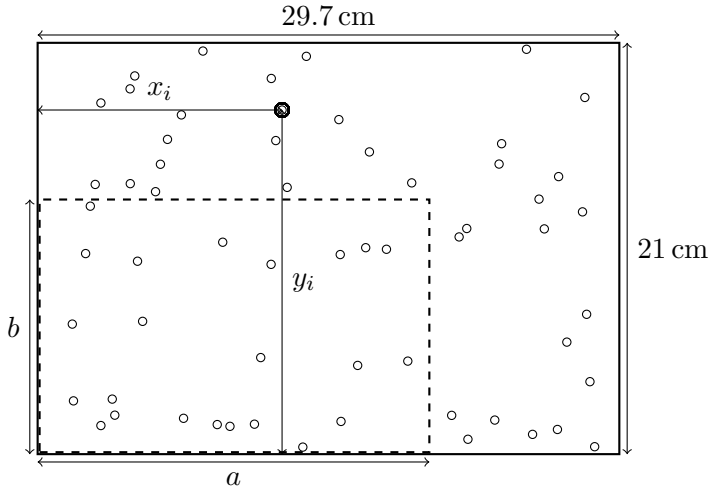

Figura 1: Risultato dell'esperimento di Anselmo. Il rettangolo tratteggiato è il contorno della piastrella, quello continuo è il contorno del foglio A4, x_i e y_i sono le coordinate del punto i-esimo (evidenziato). **Ci sono in tutto 23 punti nel rettangolo tratteggiato.**

(a) Calcolate in funzione dei parametri a e b la probabilità teorica q che un punto disegnato da Anselmo cada dentro il contorno della piastrella.

$\left(\textit{Suggerimento: se non ci riuscite, continuate assumendo} \quad q = \left(\frac{a}{29.7} \cdot \frac{b}{21} \right)^2 \right)$

(b) In base ai dati in Figura 1, fornite una stima puntuale e un intervallo di confidenza bilatero al livello del 95% per:

(i) la probabilità q richiesta nella domanda precedente;

(ii) la superficie $s = a \cdot b$ di una piastrella.

Anselmo vorrebbe piastrellare il bagno usando le piastrelle nella scatola, ma, prima di farlo, deve essere sicuro che la loro superficie s sia maggiore di $200\,\text{cm}^2$. Se le piastrelle fossero più piccole, infatti, non basterebbero a completare il lavoro, e per Anselmo l'errore più grave è credere che le piastrelle siano sufficienti quando in realtà ciò non è vero.

(c) Aiutate Anselmo a decidere se usare o meno le piastrelle nella scatola impostando un opportuno test d'ipotesi sul parametro q al livello di significatività α.

(d) Calcolate il p-value del test precedente coi dati in Figura 1 e traetene una conclusione. Si tratta di una conclusione debole o forte?

SOLUZIONE.

(a) La probabilità richiesta è $q = \mathbb{P}(X < a,\, Y < b)$. Poiché $X \sim \mathcal{U}(0, 29.7)$ e $Y \sim \mathcal{U}(0, 21)$ sono indipendenti, abbiamo

$$q = \mathbb{P}(X < a,\, Y < b) = \mathbb{P}(X < a)\, \mathbb{P}(Y < b) = \left(\int_0^a \frac{1}{29.7}\, \mathrm{d}x\right)\left(\int_0^b \frac{1}{21}\, \mathrm{d}y\right) = \frac{a}{29.7} \cdot \frac{b}{21} = \frac{ab}{623.7}\,.$$

(b) Dalla formula trovata nel punto precedente, ricaviamo

$$q = \frac{s}{623.7} \quad \Leftrightarrow \quad s = 623.7\, q\,.$$

Il parametro q è la probabilità di successo in una successione di $n = 60$ prove di Bernoulli. Uno stimatore non distorto e consistente in media quadratica per q è perciò dato dalla frequenza empirica dei successi $\bar{X}$. Per le proprietà di linearità del valore atteso e di quadraticità della varianza, uno stimatore non distorto e consistente in media quadratica per il parametro $s = 623.7\, q$ è semplicemente la variabile aleatoria $\hat{S} = 623.7\, \bar{X}$. Dai risultati dell'esperimento, otteniamo le rispettive stime ($=$ realizzazioni degli stimatori)

$$\bar{x} = \frac{23}{60} = 0.3833\,, \qquad \hat{s} = 623.7 \cdot \frac{23}{60} = 239.0850\,.$$

Essendo $n \gg 30$, sul formulario troviamo che un $IC_q(\gamma)$ è dato da

$$q \in \left(\bar{x} - z_{\frac{1+\gamma}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}\,,\, \bar{x} + z_{\frac{1+\gamma}{2}} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}\right)\,.$$

Al livello $\gamma = 95\%$ abbiamo $z_{\frac{1+\gamma}{2}} = z_{0.975} = 1.96$, e quindi l'intervallo precedente diventa

$$q \in \left(\frac{23}{60} - 1.96 \cdot \sqrt{\frac{\frac{23}{60}(1-\frac{23}{60})}{60}}\,,\, \frac{23}{60} + 1.96 \cdot \sqrt{\frac{\frac{23}{60}(1-\frac{23}{60})}{60}}\right) = (0.26031\,,\, 0.50636)\,.$$

Usando la relazione $s = 623.7\, q$, tale intervallo fornisce il seguente $IC_s(95\%)$:

$$s \in (623.7 \times 0.26031\,,\, 623.7 \times 0.50636) = (162.3542\,,\, 315.8158)\,.$$

Se invece usiamo la relazione nel suggerimento, allora

$$s = 623.7\, \sqrt{q}$$

e l'$IC_s(95\%)$ è

$$s \in \left(623.7 \times \sqrt{0.26031}\,,\, 623.7 \times \sqrt{0.50636}\right) = (318.2143\,,\, 443.8179)\,.$$

In questo caso, la variabile aleatoria $\hat{S} = 623.7\, \sqrt{\bar{X}}$ è uno stimatore approssimativamente non distorto del parametro s come conseguenza del metodo delta, e la sua realizzazione fornisce la stima

$$\hat{s} = 623.7\, \sqrt{\frac{23}{60}} = 386.1571\,.$$

(c) Per minimizzare la probabilità di accettare l'ipotesi $s > 200$ quando in realtà $s \leq 200$, dobbiamo fare un test con

$$H_0 : s \leq 200 \qquad \text{vs.} \qquad H_1 : s > 200\,.$$

In tal modo, infatti, l'errore più grave diventa l'errore di prima specie in cui si accetta H_1 quando in realtà è vera H_0, e ciò è esattamente quello che vuole Anselmo. Alla luce della relazione $s = 623.7\,q$, le ipotesi statistiche precedenti diventano

$$H_0 : q \leq \frac{200}{623.7} = 0.32067 =: q_0 \qquad \text{vs.} \qquad H_1 : q > q_0\,.$$

Si tratta quindi di un test per la probabilità di successo in una serie di prove di Bernoulli numerose. Sul formulario troviamo che una regola di rifiuto al livello α è

$$\text{“rifiuto } H_0 \text{ se } Z_0 := \frac{\bar{X} - q_0}{\sqrt{q_0(1-q_0)}}\sqrt{n} > z_{1-\alpha}\text{”}\,.$$

Se al posto della relazione $s = 623.7\,q$ avessimo usato quella del suggerimento, sarebbe cambiato solo il valore della probabilità q_0, che sarebbe stato invece $q_0 = (200/623.7)^2 = 0.10283$.

(d) Coi dati in Figura 1, otteniamo la realizzazione della statistica test

$$z_0 = \frac{\frac{23}{60} - 0.32067}{\sqrt{0.32067(1-0.32067)}}\sqrt{60} = 1.040\,.$$

Calcoliamo il p-value imponendo l'uguaglianza nella regola di rifiuto:

$$\begin{aligned} z_0 \equiv z_{1-\alpha} \quad &\Leftrightarrow \quad \Phi(z_0) \equiv \Phi(z_{1-\alpha}) = 1-\alpha \\ &\Leftrightarrow \quad \alpha = 1 - \Phi(z_0) = 1 - \Phi(1.040) = 1 - 0.85083 = 14.917\%\,. \end{aligned}$$

Un p-value del 14.917% è superiore agli usuali livelli di significatività del 5 - 10% con cui si passa dall'accettare l'ipotesi nulla H_0 al rifiutarla. In altre parole, Anselmo non ha alcuna evidenza per rifiutare $H_0 : s \leq 200$, e dunque non può fidarsi a usare le piastrelle nella scatola. Poiché si accetta H_0, tale conclusione è *debole*. Se invece avessimo usato la relazione $s = 623.7\sqrt{q}$ del suggerimento, avremmo ottenuto $z_0 = 7.154$ e quindi p-value $= 1 - \Phi(7.154) \simeq 0$. Con un p-value così basso avremmo dovuto accettare H_1, Anselmo avrebbe potuto usare le piastrelle senza farsi problemi e la conclusione sarebbe stata *forte*.

Esercizio 3. La dottoressa Bernadette Rostenkowski è una microbiologa che da tempo studia le caratteristiche di due diverse specie di batteri: il *Bacillus A* e lo *Spirillum B*. In un recente esperimento, Bernadette ha analizzato l'interazione fra queste due specie quando esse si trovano a competere nello stesso ambiente. A tale scopo, ha preparato 35 colture batteriche in cui ha aggiunto il *Bacillus A* e lo *Spirillum B* con le rispettive concentrazioni variabili `A` e `B` (in ufc/ml, cioè *unità formanti colonie per millilitro*). Ha poi determinato il `consumo` (in g/l) di zucchero in ogni coltura, misurando la differenza fra la concentrazione di zucchero iniziale e quella rilevata 48 ore dopo l'aggiunta dei batteri. Infine, Bernadette ha cercato un modello di regressione lineare che si adattasse il più possibile ai dati raccolti, ottenendo dopo vari tentativi quello riportato nella pagina seguente. Sotto il modello si trovano anche i grafici di diagnostica dei residui.

(a) Scrivete la relazione fra la variabile `consumo` e le variabili `A` e `B` nel modello trovato da Bernadette. Elencate tutti i parametri incogniti di tale modello.

(b) Commentate il modello, indicando in particolare:

- se spiega a sufficienza la variabilità dei dati in uscita;
- se rispetta le ipotesi alla base del modello lineare gaussiano;
- se tutti i suoi regressori sono significativi.

Giustificate opportunamente le vostre affermazioni.

(c) Determinate quale fra i parametri del modello descrive il consumo di zucchero atteso in una coltura in cui non sono presenti né il *Bacillus A* né lo *Spirillum B*. Fornite poi un intervallo di confidenza bilatero al livello del 95% per tale parametro.

(d) Bernadette ritiene che il *Bacillus A* e lo *Spirillum B* non siano i soli responsabili del consumo di zucchero nelle colture, e sospetta che tale consumo sia mediamente superiore a $5 \cdot 10^{-1}$ g/l anche in assenza delle due specie di batteri. Impostate un test opportuno per decidere se il sospetto di Bernadette è confermato dai dati, determinate un intervallo in cui cade il suo p-value e traetene una conclusione.

(e) Fornite una previsione puntuale per il consumo di zucchero in una coltura che non contenga il *Bacillus A*, ma che contenga invece lo *Spirillum B* nella concentrazione di $2 \cdot 10^4$ ufc/ml.

(f) A parere di Bernadette, i dati dimostrano che le due specie di batteri interagiscono fra loro ostacolandosi a vicenda. In altre parole, quando sia il *Bacillus A* sia lo *Spirillum B* sono presenti nella stessa coltura, secondo lei il consumo di zucchero atteso è significativamente minore di quanto si avrebbe se non ci fosse interazione. Siete d'accordo su questo punto con Bernadette? Decidete impostando un nuovo test, determinando un intervallo per il suo p-value e traendo anche qui una conclusione.

```
Call:
lm(formula = consumo ~ A + B + A:B)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.102722 -0.039109 -0.004159  0.037261  0.099370 

Coefficients:
              Estimate Std. Error t value Pr(>|t|)    
(Intercept)  5.679e-01  1.006e-01   5.644 3.39e-06 ***
A            3.812e-05  2.841e-06  13.419 1.87e-14 ***
B            1.171e-04  6.656e-06  17.599  < 2e-16 ***
A:B         -2.924e-09  1.858e-10 -15.737 2.48e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.05297 on 31 degrees of freedom
Multiple R-squared:  0.9245,	Adjusted R-squared:  0.9172 
F-statistic: 126.6 on 3 and 31 DF,  p-value: < 2.2e-16
```

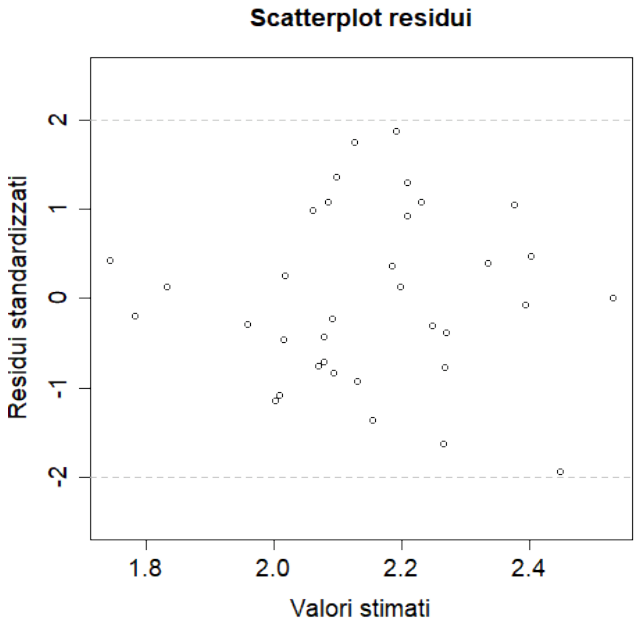

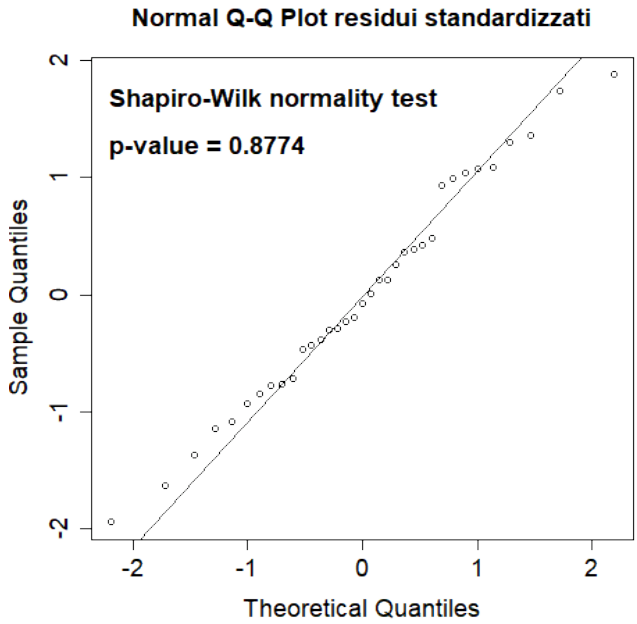

SOLUZIONE.

(a) Il modello di Bernadette è

$$\texttt{consumo}_i = \beta_0 + \beta_1\,\texttt{A}_i + \beta_2\,\texttt{B}_i + \beta_3\,\texttt{A}_i \cdot \texttt{B}_i + E_i$$

con $E_1, \ldots, E_{35}$ i.i.d. e $E_i \sim N(0, \sigma^2)$. I parametri incogniti di tale modello sono i quattro coefficienti β_0, β_1, β_2, β_3 e l'intensità σ^2 del rumore gaussiano.

(b) Il modello di Bernadette spiega a sufficienza la variabilità dei dati in uscita, in quanto la sua percentuale di variabilità spiegata $r^2_{\text{adj}} = 0.9172$ è ben maggiore dell'usuale soglia dell'81% che caratterizza un buon modello. Sono anche rispettate le ipotesi alla base del modello lineare gaussiano, dal momento che i residui sono omoschedastici (scatterplot a nuvola e senza pattern particolari), si allineano molto bene alla Q-Q line nel normal Q-Q plot e presentano un p-value del test di Shapiro-Wilk pari all'87.74% e dunque ben maggiore degli usuali livelli per cui si rifiuta l'ipotesi nulla di gaussianità. Infine, tutti i regressori sono significativi, in quanto i p-value dei rispettivi T-test sono estremamente bassi ($1.87 \cdot 10^{-14}$, $< 2 \cdot 10^{-16}$ e $2.48 \cdot 10^{-16}$) e dunque permettono di rifiutare l'ipotesi nulla $H_0 : \beta_i = 0$ a favore dell'alternativa $H_1 : \beta_i \neq 0$.

(c) In una coltura in cui non sono presenti nè il *Bacillus A* nè lo *Spirillum B*, il consumo di zucchero atteso è il parametro

$$\begin{aligned}\mathbb{E}\left(\texttt{consumo} \mid \texttt{A} = 0,\, \texttt{B} = 0\right) &= \mathbb{E}\left(\beta_0 + \beta_1\,\texttt{A} + \beta_2\,\texttt{B} + \beta_3\,\texttt{A} \cdot \texttt{B} + E \mid \texttt{A} = 0,\, \texttt{B} = 0\right) \\ &= \mathbb{E}\left(\beta_0 + E\right) = \beta_0 + \mathbb{E}\left(E\right) = \beta_0\,.\end{aligned}$$

Un $IC_{\beta_0}(\gamma)$ è dato da

$$\beta_0 \in \left(\hat{\beta}_0 - t_{\frac{1+\gamma}{2}}(n-k-1)\,\text{se}(\hat{\beta}_0)\,,\, \hat{\beta}_0 + t_{\frac{1+\gamma}{2}}(n-k-1)\,\text{se}(\hat{\beta}_0)\right)\,.$$

Nella summary di R leggiamo i valori $\hat{\beta}_0 = 5.679 \cdot 10^{-1}$ e $\text{se}(\hat{\beta}_0) = 1.006 \cdot 10^{-1}$, mentre con $\gamma = 95\%$ sulle tavole delle distribuzioni troviamo $t_{\frac{1+\gamma}{2}}(n-k-1) = t_{0.975}(35-3-1) \simeq t_{1-\alpha}(30) = 2.0423$. L'intervallo diventa perciò

$$\begin{aligned}\beta_0 \in \left(5.679 \cdot 10^{-1} - 2.0423 \cdot 1.006 \cdot 10^{-1}\,,\, 5.679 \cdot 10^{-1} + 2.0423 \cdot 1.006 \cdot 10^{-1}\right) \\ = \left(3.6244 \cdot 10^{-1}\,,\, 7.7336 \cdot 10^{-1}\right)\,.\end{aligned}$$

(d) Per quanto visto al punto (c), il sospetto di Bernadette si traduce nell'ipotesi statistica $\beta_0 > 5 \cdot 10^{-1}$. Per decidere se tale ipotesi è confermata dai dati, dobbiamo fare un test in cui

$$H_0 : \beta_0 \leq 5 \cdot 10^{-1} := \beta_{0,0} \qquad \text{vs.} \qquad H_0 : \beta_0 > \beta_{0,0}\,.$$

Per mettere a confronto H_0 e H_1, possiamo usare la seguente regola di rifiuto al livello α:

$$\text{“rifiuto } H_0 \text{ se } T_0 := \frac{\hat{B}_0 - \beta_{0,0}}{\text{se}(\hat{B}_0)} > t_{1-\alpha}(n-k-1)\text{”}\,.$$

Dall'output di R, troviamo la realizzazione

$$t_0 = \frac{5.679 \cdot 10^{-1} - 5 \cdot 10^{-1}}{1.006 \cdot 10^{-1}} = 0.6750\,.$$

Ricaviamo il p-value imponendo l'uguaglianza nella regola di rifiuto:

$$t_0 \equiv t_{1-\alpha}(n-k-1) = t_{1-\alpha}(35-3-1) = t_{1-\alpha}(31)\,.$$

Poiché $t_0 = 0.67495 < 0.6828 = t_{0.75}(30) \simeq t_{0.75}(31)$, segue che $1-\alpha < 0.75$ e dunque $\alpha > 25\%$. Con un p-value così alto non abbiamo nessun motivo di dubitare di H_0 e quindi il sospetto di Bernadette non ha alcun fondamento (conclusione debole).

(e) La previsione puntuale in corrispondenza del nuovo input $\texttt{A} = 0$ e $\texttt{B} = 2 \cdot 10^4$ è

$$\begin{aligned}\widehat{\texttt{consumo}} &= \hat\beta_0 + \hat\beta_1\,\texttt{A} + \hat\beta_2\,\texttt{B} + \hat\beta_3\,\texttt{A}\cdot\texttt{B}\\ &= 5.679\cdot 10^{-1} + 3.812\cdot 10^{-5}\cdot 0 + 1.171\cdot 10^{-4}\cdot 2\cdot 10^4 - 2.924\cdot 10^{-9}\cdot 0\cdot 2\cdot 10^4\\ &= 2.9099\,.\end{aligned}$$

(f) Questa volta l'ipotesi sostenuta da Bernadette è $\beta_3 < 0$, e come nel punto (d), per cercare evidenza in suo favore, dobbiamo fare un test per le ipotesi

$$H_0 : \beta_3 \geq 0 =: \beta_{3,0} \qquad \text{vs.} \qquad H_0 : \beta_3 < \beta_{3,0}\,.$$

La regola è

$$\text{“rifiuto } H_0 \text{ se } T_0 := \frac{\hat B_3 - \beta_{3,0}}{\mathrm{se}(\hat B_3)} < -t_{1-\alpha}(n-k-1)\text{”}$$

e dai dati ricaviamo

$$\frac{-2.924\cdot 10^{-9} - 0}{1.858\cdot 10^{-10}} = -15.7373\,,$$

che non è altro che il valore del `t value` nella summary di R. Per trovare il p-value, ora risolviamo

$$t_0 = -15.7373 \equiv -t_{1-\alpha}(n-k-1) = -t_{1-\alpha}(31) \quad\Leftrightarrow\quad 15.7373 = t_{1-\alpha}(31)\,.$$

Il valore 15.7373 è ben più alto di tutti i quantili tabulati, perciò $1-\alpha \simeq 100\%$ o, equivalentemente, $\alpha \simeq 0$. In altre parole, il p-value è infimo e quindi questa volta abbiamo fortissima evidenza a favore di H_1.