Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

III appello di Statistica per Ingegneria Fisica
30 agosto 2023

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Esercizio 1. La gallina Chiquita depone ogni giorno un numero di uova X che si può modellizzare con una variabile aleatoria discreta a valori nell'insieme dei numeri interi $\{0, 1, 2, \ldots\}$. È noto che in un giorno qualsiasi Chiquita depone:

- almeno 2 uova con probabilità 20%;

- al massimo 2 uova con probabilità 99.5%;

- esattamente 3 uova con probabilità 0.5%.

(a) Qual è la probabilità che in un giorno qualsiasi Chiquita deponga almeno 4 uova?

È noto inoltre che

- in giorni diversi Chiquita depone quantità di uova indipendenti;

- la probabilità che Chiquita non deponga nessun uovo per due giorni di seguito è pari al 25%.

(b) Determinate la densità di probabilità (discreta) di X.

(c) Qual è la probabilità (eventualmente approssimata) che Chiquita deponga almeno 2 uova per più di 15 giorni su 100?

(d) E qual è la probabilità (sempre eventualmente approssimata) che Chiquita deponga esattamente 3 uova per più di 2 giorni su 100?

Sia Y la variabile aleatoria che conta per quanti giorni su 100 Chiquita depone almeno 2 uova (domanda (c)) e Z quella che conta per quanti giorni su 100 ne depone esattamente 3 (domanda (d)).

(e) Quale approssimazione si può usare per la variabile aleatoria Y? E quale per Z? Giustificate opportunamente la risposta.

SOLUZIONE.

(a) Poiché X può prendere valori soltanto nell'insieme dei numeri interi $\{0, 1, 2, \ldots\}$, abbiamo

$$\begin{aligned}\mathbb{P}(X \geq 4) &= 1 - \mathbb{P}(X < 4) = 1 - \mathbb{P}(X \leq 3) = 1 - \mathbb{P}(\text{“}X \leq 2\text{”} \vee \text{“}X = 3\text{”}) \\ &= 1 - (\mathbb{P}(X \leq 2) + \mathbb{P}(X = 3)) \qquad (\text{perché “}X \leq 2\text{”} \wedge \text{“}X = 3\text{”} = \emptyset) \\ &= 1 - (99.5\% + 0.5\%) = 0\,.\end{aligned}$$

In altre parole, è impossibile che in un giorno Chiquita deponga almeno 4 uova.

(b) Poiché $\mathbb{P}(X \geq 4) = 0$, possiamo restringere la densità discreta p di X soltanto all'insieme $\{0, 1, 2, 3\}$. Dal testo ricaviamo

$$\begin{cases} 20\% = \mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X < 2) = 1 - (p(0) + p(1)) \\ 99.5\% = \mathbb{P}(X \leq 2) = p(0) + p(1) + p(2) \\ 0.5\% = \mathbb{P}(X = 3) = p(3) \end{cases} \quad \Rightarrow \quad \begin{cases} p(0) + p(1) = 80\% \\ p(2) = 19.5\% \\ p(3) = 0.5\% \end{cases} .$$

Se X_1 è il numero di uova deposte in un giorno e X_2 quello di uova deposte il giorno dopo, sempre dal testo sappiamo che X_1 e X_2 sono indipendenti, e

$$25\% = \mathbb{P}(\text{“}X_1 = 0\text{”} \wedge \text{“}X_2 = 0\text{”}) = \mathbb{P}(X_1 = 0) \cdot \mathbb{P}(X_2 = 0) = p(0)^2 .$$

Segue che $p(0) = \sqrt{25\%} = 50\%$ e, poiché $p(0) + p(1) = 80\%$, otteniamo $p(1) = 80\% - 50\% = 30\%$. La densità completa è quindi

$$p(0) = 50\% , \qquad p(1) = 30\% , \qquad p(2) = 19.5\% , \qquad p(3) = 0.5\% .$$

(c) Sia Y la variabile aleatoria che conta per quanti giorni dei 100 fissati Chiquita depone almeno 2 uova. Poiché Y conta il numero di successi in $n = 100$ prove di Bernoulli in cui ogni prova ha probabilità di successo pari a $q = 20\%$, si ha $Y \sim B(n, q)$. Possiamo usare l'approssimazione normale della densità binomiale $B(n, q) \simeq N(nq, nq(1-q)) = N(20, 16)$, in quanto sono soddisfatte tutte e tre le condizioni

$$n = 100 > 20 , \qquad nq = 20 > 5 , \qquad n(1-q) = 80 > 5 .$$

La probabilità cercata è pertanto

$$\begin{aligned} \mathbb{P}(Y > 15) &= \mathbb{P}\left(\underbrace{\frac{Y - nq}{\sqrt{nq(1-q)}}}_{\sim N(0,1)} > \frac{15 - 100 \cdot 20\%}{\sqrt{100 \cdot 20\% \cdot (1 - 20\%)}} \right) \simeq 1 - \Phi\left(\frac{15 - 100 \cdot 20\%}{\sqrt{100 \cdot 20\% \cdot (1 - 20\%)}} \right) \\ &= 1 - \Phi(-1.25) = \Phi(1.25) = 0.89435 = 89.435\% . \end{aligned}$$

Con la correzione di continuità,

$$\begin{aligned} \mathbb{P}(Y > 15) = \mathbb{P}(Y \geq 15.5) = \ldots &\simeq 1 - \Phi\left(\frac{15.5 - 100 \cdot 20\%}{\sqrt{100 \cdot 20\% \cdot (1 - 20\%)}} \right) \\ &= 1 - \Phi(-1.125) = \Phi(1.125) = \frac{0.86864 + 0.87076}{2} = 86.970\% . \end{aligned}$$

(d) In modo simile al punto precedente, la variabile aleatoria Z che conta per quanti giorni su 100 Chiquita depone esattamente 3 uova ha densità $B(n, q')$ con $n = 100$ e $q' = 0.5\%$. In questo caso, però, le condizioni per l'approssimazione gaussiana non sono soddisfatte, in quanto $nq' = 0.5 < 5$. Per calcolare la probabilità richiesta dobbiamo quindi usare la densità esatta:

$$\begin{aligned} \mathbb{P}(Z > 2) &= 1 - \mathbb{P}(Z \leq 2) = 1 - \sum_{k=0}^{2} \binom{n}{k} q'^k (1 - q')^{n-k} \\ &= 1 - \left(\binom{100}{0} 0.5\%^0 (1 - 0.5\%)^{100-0} + \binom{100}{1} 0.5\%^1 (1 - 0.5\%)^{100-1} \right. \\ &\quad \left. + \binom{100}{2} 0.5\%^2 (1 - 0.5\%)^{100-2} \right) \\ &= 1 - \left(1 \cdot 1 \cdot 99.5\%^{100} + 100 \cdot 0.5\% \cdot 99.5\%^{99} + 4\,950 \cdot 0.5\%^2 \cdot 99.5\%^{98} \right) \\ &= 1.41029\% . \end{aligned}$$

(e) Abbiamo già visto nel punto (c) che per la variabile aleatoria Y si può usare l'approssimazione normale della densità binomiale $B(100, 20\%) \simeq N(20, 16)$. Per la variabile aleatoria Z, invece, osserviamo che $n = 100 > 20$ e $nq' = 0.5 \simeq 1$. Sono quindi soddisfatte le condizioni per usare l'approssimazione poissoniana della densità binomiale $B(100, 0.5\%) \simeq \mathcal{P}(100 \cdot 0.5\%) = \mathcal{P}(0.5)$. Osserviamo che con tale approssimazione la probabilità già ricavata nel punto (d) diventa

$$\mathbb{P}(Z > 2) \simeq 1 - \sum_{k=0}^{2} \mathrm{e}^{-nq'} \frac{(nq')^k}{k!} = 1 - \mathrm{e}^{-0.5} \left(\frac{0.5^0}{0!} + \frac{0.5^1}{1!} + \frac{0.5^2}{2!} \right) = 1.43877\% \,,$$

che è molto vicina al valore esatto 1.41029% ricavato nel punto (d)

Esercizio 2. Secondo la "Canzone dei Puffi", i folletti blu sono alti su per giù due mele o poco più. In realtà, l'altezza X di un puffo qualsiasi, rapportata a quella di una mela, è data dalla somma $X = a + Y$, dove a è un parametro reale incognito e Y è una variabile aleatoria assolutamente continua avente densità

$$f_Y(y) = \begin{cases} \frac{1}{4}(3 - 2|y|) & \text{se } y \in [-b, b] \\ 0 & \text{altrimenti} \end{cases} .$$

Nell'espressione precedente, $b > 0$ è un altro parametro reale da determinare.

(a) Trovate per quale valore del parametro b la funzione f_Y è effettivamente la densità di probabilità di una variabile aleatoria assolutamente continua. Per tale valore, disegnate un grafico qualitativo di f_Y.

D'ora in poi, assumete che b abbia il valore trovato al punto precedente.

(b) Calcolate $\mathbb{E}(X)$, $\mathbb{E}(Y)$, $\mathrm{Var}(X)$ e $\mathrm{Var}(Y)$.
(Se non ci siete riusciti, continuate assumendo $\mathbb{E}(X) = a/2$ *e* $\mathrm{Var}(X) = 3/2$*.)*

Per determinare il parametro a, Gargamella cattura 50 puffi e ne misura le altezze, ottenendo così il campione aleatorio $X_1, \ldots, X_{50}$. Basandosi solo sulle prime 5 misure, egli propone poi il seguente stimatore di a:

$$\hat{A} = c(X_1 + X_2 + X_3 + X_4) - X_5 ,$$

in cui c è un ulteriore parametro reale.

(c) Individuate il valore di c per cui $\hat{A}$ è uno stimatore non distorto di a. Assumendo che c abbia tale valore, calcolate l'errore quadratico medio di $\hat{A}$.

Gargamella vuole sottoporre a verifica quanto affermato nella "Canzone dei Puffi", cioè che il valore atteso $\mathbb{E}(X)$ sia maggiore di 2. Ovviamente, l'errore più grave per lui è contestare la canzone quando in realtà essa dichiara il vero. Gargamella non vuole commettere questo errore con probabilità superiore al 5%.

(d) Impostate un test opportuno per decidere fra le ipotesi $\mathbb{E}(X) > 2$ ed $\mathbb{E}(X) < 2$ in base a tutte le 50 misure a disposizione. Nel test fate in modo che la probabilità di concludere che $\mathbb{E}(X) < 2$ quando in realtà $\mathbb{E}(X) > 2$ non superi (almeno approssimativamente) il 5%, come richiesto da Gargamella..

(e) Determinate la potenza approssimata del test del punto precedente in funzione del parametro a. Per quale valore di a nell'intervallo $[1.70, 1.90]$ la potenza del test è massima?

Dopo aver misurato le altezze dei 50 puffi, Gargamella trova la media campionaria $\bar{x}_{50} = 1.94$.

(f) Come si conclude il test impostato al punto (d) in base ai dati di Gargamella? Qual è il p-value di tale test? Quale conclusione ne traete?

SOLUZIONE.

(a) Affinché f_Y sia effettivamente la densità di probabilità di una variabile aleatoria assolutamente continua, devono essere soddisfatte le due condizioni

(i) $f_Y(y) \geq 0$ per ogni y;
(ii) $\int_{-\infty}^{+\infty} f_Y(y)\,\mathrm{d}y = 1$.

La condizione (ii) implica che

$$1 = \int_{-b}^{b} \frac{1}{4}\left(3 - 2\,|y|\right) \mathrm{d}y = \frac{1}{4}\left(3\int_{-b}^{b} \mathrm{d}y + 2\int_{-b}^{0} y\,\mathrm{d}y - 2\int_{0}^{b} y\,\mathrm{d}y\right) = \frac{1}{4}\left(3\,[y]_{-b}^{b} + \left[y^2\right]_{-b}^{0} - \left[y^2\right]_{0}^{b}\right)$$
$$= \frac{1}{4}\left(6b - 2b^2\right) \quad \Leftrightarrow \quad b = 1 \quad \text{oppure} \quad b = 2\,.$$

La soluzione $b = 2$ è esclusa dalla condizione (i), in quanto la positività di f_Y richiede che

$$\frac{1}{4}\left(3 - 2\,|y|\right) \geq 0 \text{ per ogni } y \in [-b, b] \quad \Leftrightarrow \quad |y| \leq \frac{3}{2} \text{ per ogni } y \in [-b, b] \quad \Leftrightarrow \quad b \leq \frac{3}{2}\,.$$

L'espressione finale di f_Y e il suo grafico sono quindi i seguenti:

$$f_Y(y) = \begin{cases} \frac{1}{4}\left(3 - 2\,|y|\right) & \text{se } y \in [-1, 1] \\ 0 & \text{altrimenti} \end{cases}\,.$$

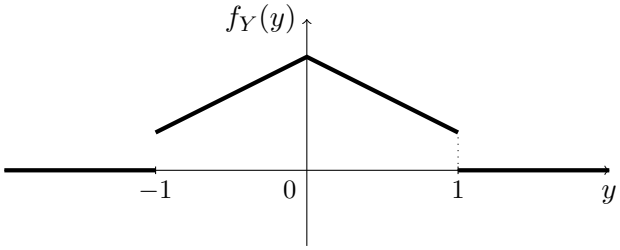

(b) Osserviamo che f_Y è simmetrica rispetto all'origine, dunque

$$\mathbb{E}\left(Y\right) = 0 \quad \Rightarrow \quad \mathbb{E}\left(X\right) = \mathbb{E}\left(a + Y\right) = a + \mathbb{E}\left(Y\right) = a\,.$$

Per quanto riguarda invece la varianza, abbiamo

$$\mathrm{Var}\left(Y\right) = \int_{-\infty}^{+\infty} \left(y - \mathbb{E}\left(Y\right)\right)^2 f_Y(y)\,\mathrm{d}y = \int_{-1}^{1} y^2 \frac{1}{4}\left(3 - 2\,|y|\right) \mathrm{d}y$$
$$= \frac{1}{4}\left(3\int_{-1}^{1} y^2 \mathrm{d}y + 2\int_{-1}^{0} y^3 \mathrm{d}y - 2\int_{0}^{1} y^3 \mathrm{d}y\right) = \frac{1}{4}\left(\left[y^3\right]_{-1}^{1} + \frac{1}{2}\left[y^4\right]_{-1}^{0} - \frac{1}{2}\left[y^4\right]_{0}^{1}\right)$$
$$= \frac{1}{4} \quad \Rightarrow \quad \mathrm{Var}\left(X\right) = \mathrm{Var}\left(a + Y\right) = \mathrm{Var}\left(Y\right) = \frac{1}{4}\,.$$

(c) Per la linearità del valore atteso, abbiamo

$$\mathbb{E}(\hat{A}) = \mathbb{E}\left(c\left(X_1 + X_2 + X_3 + X_4\right) - X_5\right) = c\left(\mathbb{E}\left(X_1\right) + \mathbb{E}\left(X_2\right) + \mathbb{E}\left(X_3\right) + \mathbb{E}\left(X_4\right)\right) - \mathbb{E}\left(X_5\right)$$
$$= c\left(a + a + a + a\right) - a = \left(4c - 1\right) a\,.$$

Perciò,

$$\mathrm{bias}(\hat{A}; a) = \mathbb{E}(\hat{A}) - a \equiv 0 \quad \Leftrightarrow \quad c = \frac{1}{2}\,.$$

Per tale valore di c, usando l'indipendenza delle X_i e le proprietà della varianza, troviamo che

$$\mathrm{Var}(\hat{A}) = \mathrm{Var}\left(c\left(X_1 + X_2 + X_3 + X_4\right) - X_5\right)$$
$$= c^2\mathrm{Var}\left(X_1\right) + c^2\mathrm{Var}\left(X_2\right) + c^2\mathrm{Var}\left(X_3\right) + c^2\mathrm{Var}\left(X_4\right) + (-1)^2\mathrm{Var}\left(X_5\right)$$
$$= \frac{c^2}{4} + \frac{c^2}{4} + \frac{c^2}{4} + \frac{c^2}{4} + \frac{1}{4} = \frac{1}{2}$$

e quindi

$$\mathrm{mse}(\hat{A}; a) = \mathrm{Var}(\hat{A}) + \mathrm{bias}(\hat{A}; a)^2 = \frac{1}{2} + 0^2 = \frac{1}{2}\,.$$

Coi valori di $\mathbb{E}\left(X\right)$ e di $\mathrm{Var}\left(X\right)$ dati nel suggerimento troviamo invece $\mathbb{E}(\hat{A}) = (2c - 1/2)\,a$ e $\mathrm{Var}(\hat{A}) = (6c^2 + 3/2)$. Con questi valori, $\hat{A}$ è non distorto quando $c = 3/4$ e in tal caso $\mathrm{mse}(\hat{A}; a) = 39/8$.

(d) Se vogliamo impostare un test in cui l'errore più grave sia contestare la canzone dei puffi quando in realtà essa dichiara il vero, dobbiamo mettere nell'ipotesi nulla quanto affermato dalla canzone (cioè $\mathbb{E}(X) > 2$) e nell'alternativa il suo contrario. Solo così, infatti, l'errore più grave diventa quello di I tipo in cui si rifiuta H_0 (cioè quanto affermato dalla canzone) quando in realtà essa è vera. Se non vogliamo commettere quest'errore con probabilità superiore al 5%, il livello di significatività del test dovrà essere $\alpha = 5\%$. Per confrontare le ipotesi

$$H_0 : \mathbb{E}(X) \geq 2 \quad \text{vs.} \quad H_1 : \mathbb{E}(X) < 2$$

possiamo fare uno Z-test per il valore atteso di un campione non gaussiano ma numeroso e a varianza nota, in cui la regola è

$$\text{“rifiuto } H_0 \text{ se } Z_0 := \frac{\bar{X}_n - \mu_0}{\sigma}\sqrt{n} < -z_{1-\alpha}\text{”}$$

dove $\mu_0 = 3$, $\sigma = \sqrt{1/4} = 0.5$ ($\sigma = \sqrt{3/2}$ coi valori del suggerimento), $n = 50$ e $z_{1-\alpha} = z_{0.95} = 1.645$.

(e) La potenza del test è

$$\begin{aligned}
\pi &= \mathbb{P}_{H_0 \text{ falsa}}(\text{“rifiuto } H_0\text{”}) = \mathbb{P}_{\mathbb{E}(X)<2}\left(\frac{\bar{X}_n - \mu_0}{\sigma}\sqrt{n} < -z_{1-\alpha}\right) \\
&= \mathbb{P}_{\mathbb{E}(X)<2}\left(\underbrace{\frac{\bar{X}_n - \mathbb{E}(X)}{\sigma}\sqrt{n}}_{\approx N(0,1)} < -z_{1-\alpha} + \frac{\mu_0 - \mathbb{E}(X)}{\sigma}\sqrt{n}\right) \\
&\simeq \Phi\left(-z_{1-\alpha} + \frac{\mu_0 - \mathbb{E}(X)}{\sigma}\sqrt{n}\right)
\end{aligned}$$

e la sua espressione in funzione del parametro a si ottiene sostituendo $\mathbb{E}(X) = a$ o $\mathbb{E}(X) = a/2$ a seconda che si usi il valore corretto oppure quello del suggerimento. In entrambi i casi la potenza è una funzione decrescente di $\mathbb{E}(X)$ e quindi di a (un test è 'tanto più potente quanto più H_1 è vera'). Perciò, il valore di a nell'intervallo $[1.70, 1.90]$ che rende massima la potenza è l'estremo $a = 1.70$.

(f) La realizzazione della statistica test coi dati di Gargamella è

$$z_0 = \frac{1.94 - 2}{0.5}\sqrt{50} = -0.84853 \qquad (z_0 = -0.34641 \text{ coi valori del suggerimento}).$$

Poiché $z_0 \not< -z_{0.95} = -1.645$, non possiamo rifiutare H_0 al livello di significatività del 5%. Per calcolare il p-value, imponiamo l'uguaglianza nella regola di rifiuto al livello α:

$$\begin{aligned}
z_0 \equiv -z_{1-\alpha} = z_\alpha \quad \Leftrightarrow \quad \alpha &= \Phi(z_\alpha) \equiv \Phi(z_0) = \Phi(-0.84853) = 1 - \Phi(0.84853) = 1 - 0.80234 \\
&= 19.766\% \qquad \left(= 1 - \frac{0.63307 + 0.63683}{2} = 36.505\% \text{ col suggerimento}\right).
\end{aligned}$$

Un p-value del 19.766% (o del 36.505%), ben maggiore persino del 10%, non mostra alcuna evidenza per rifiutare l'ipotesi nulla H_0. Dunque Gargamella non può contestare quanto affermato dalla "Canzone dei Puffi".

Esercizio 3. Il fisico Leo Galli decide di ripetere il leggendario esperimento con cui il suo celebre omonimo studiò la caduta dei gravi. Dotato di un moderno e sofisticato strumento di misura, Leo lascia cadere masse di `materiale` diverso dalla sommità di una torre, e registra la `distanza` (in m) dal suolo di tali masse in funzione del `tempo` (in s) trascorso dal lancio. Egli ripete varie volte l'esperimento, prima lanciando una palla di `piombo` e poi una palla di `sughero`. Lo scatterplot seguente rappresenta i dati ottenuti, con a fianco uno screenshot estratto dalla console di R.

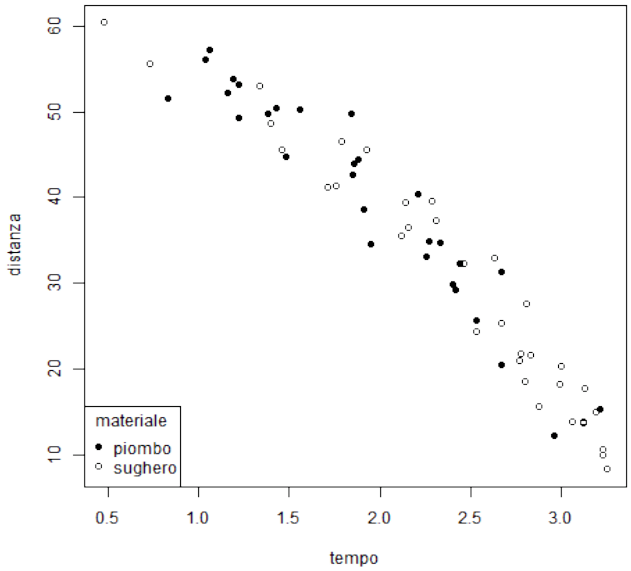


```
> mean( tempo )
[1] 2.179841
> mean( distanza )
[1] 34.45032
> sd( tempo )
[1] 0.72959
> sd( distanza )
[1] 14.47252
```

Elaborando questi dati con un modello di regressione lineare, Leo ricava l'output e la diagnostica dei residui che riportiamo nella prossima pagina. Purtroppo, la stampante del Politecnico non è moderna e sofisticata come lo strumento di misura usato da Leo, e per questo la summary di R risulta illegibile in alcune parti.

(a) Scrivete la relazione tra le variabili `distanza`, `tempo` e `materiale` nel modello elaborato da Leo. Quale valore numerico è stato assegnato da R a ciascuno dei due livelli della variabile categorica `materiale`?

(b) Determinate la percentuale di variabilità spiegata dal modello di Leo. È una percentuale sufficiente?

Secondo una ben nota formula cinematica, la `distanza` attesa è legata al `tempo` dalla relazione

$$\mathbb{E}\,(\texttt{distanza}) = h - \frac{1}{2}\, g\, \texttt{tempo}^2\,,$$

in cui h è l'altezza iniziale da cui vengono lasciate cadere le masse e g è l'accelerazione di gravità **che può eventualmente dipendere dal `materiale` lanciato.**

(c) Fornite un intervallo di confidenza bilatero al livello del 95% per l'altezza iniziale h.

(d) C'è evidenza dai dati che l'accelerazione di gravità g dipenda dal tipo di `materiale` lanciato? Per rispondere, individuate quale coefficiente del modello descrive la differenza fra l'accelerazione di gravità del `piombo` e quella del `sughero`. Impostate poi un test opportuno su tale coefficiente, determinate il suo p-value e traetene una conclusione.

(e) C'è evidenza dai dati che il `piombo` abbia accelerazione di gravità g diversa da $9.81\,\mathrm{m/s^2}$? Anche qui, impostate un test su un opportuno coefficiente e per rispondere basatevi sul suo p-value.

(f) Fornite una previsione puntuale per la `distanza` dal suolo di una palla di `sughero` dopo 2 s dal lancio.

(g) Sotto quali ipotesi le risposte che avete dato alle domande (c), (d), (e), (f) possono considerarsi attendibili? Tali ipotesi sono rispettate dai dati? Perché?

```
Call:
lm(formula = distanza ~ I(tempo^2) + I(tempo^2):materiale)

Residuals:
    Min      1Q  Median      3Q     Max 
-6.4453 -2.3853 [redacted] 6.7337 

Coefficients:
                              Estimate Std. Error t value Pr(>|t|)    
(Intercept)                    59.0124     0.8630 [redacted]  <2e-16 ***
I(tempo^2)                     -4.7277     0.2031 -23.280 [redacted] ***
I(tempo^2):materialesughero     0.1106     0.1583   0.699    0.487    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.258 on 60 degrees of freedom
Multiple R-squared: [redacted]     Adjusted R-squared: [redacted]
F-statistic: 581.7 on 2 and 60 DF,  p-value: < 2.2e-16
```

Summary del modello

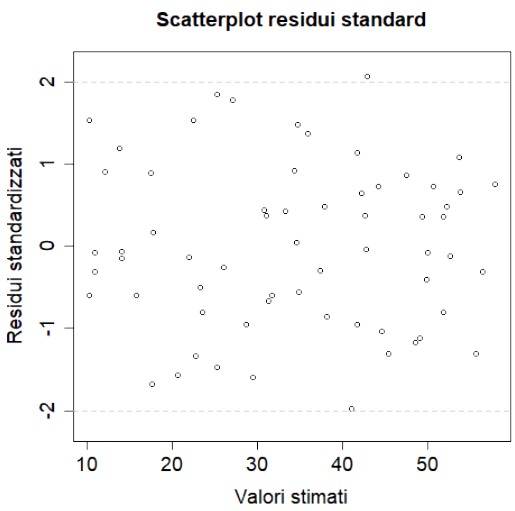

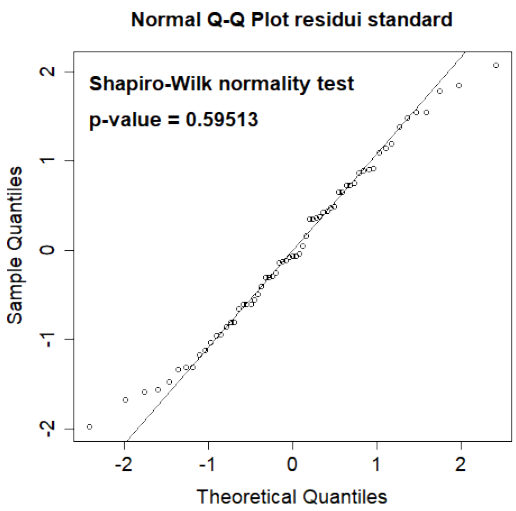

Diagnostica dei residui

SOLUZIONE.

(a) Il modello è

$$\texttt{distanza}_i = \beta_0 + \beta_1\,\texttt{tempo}_i^2 + \beta_2\,\texttt{tempo}_i^2 \cdot \texttt{materialesughero}_i + E_i$$

in cui $E_1, \ldots, E_{63}$ sono i.i.d., $E_i \sim N(0, \sigma^2)$ e σ^2 è incognita. Il numero di punti $n = 63$ si ricava ad esempio dai gradi di libertà del numeratore della F-statistic, che sono $n - k - 1 = 60$ poiché il modello ha $k = 2$ predittori. Secondo la convenzione di R, il regressore (numerico) `materialesughero` prende il valore 1 se il `materiale` è il `sughero` e il valore 0 nel caso del `piombo`.

(b) La percentuale di variabilità spiegata dal modello è il suo coefficiente di determinazione r^2, eventualmente aggiustato tenendo conto del numero $k = 2$ dei regressori. I valori di r^2 e di r^2_{adj} non sono leggibili nell'output, ma si possono facilmente ricavare dalle definizioni

$$r^2 = \frac{ss_r}{ss_t} = 1 - \frac{ss_e}{ss_t}\,, \qquad r^2_{\text{adj}} = 1 - \frac{ss_e}{ss_t}\,\frac{n-1}{n-k-1}\,,$$

nelle quali ss_r, ss_e e ss_t sono rispettivamente la varianza spiegata, residua e totale del modello. La varianza totale ss_t si ottiene dallo screenshot della console di R utilizzando le relazioni

$$ss_t = s_{yy} = (n-1) \cdot \texttt{sd(distanza)}^2 = (63-1) \cdot 14.47252^2 = 12\,986.138\,.$$

Quella residua invece si ottiene dal valore del residual standard error $\hat{\sigma} = 3.258$ secondo la formula

$$\hat{\sigma}^2 = \frac{ss_e}{n-k-1} \quad \Rightarrow \quad ss_e = (n-k-1) \cdot \hat{\sigma}^2 = (63-2-1) \cdot 3.258^2 = 636.874\,.$$

Ricaviamo quindi

$$r^2 = 1 - \frac{636.874}{12\,986.138} = 95.096\%\,, \qquad r^2_{\text{adj}} = 1 - \frac{636.874}{12\,986.138}\,\frac{63-1}{63-2-1} = 94.932\%\,,$$

che sono entrambe percentuali molto soddisfacenti e ben oltre l'usuale soglia dell'80 - 81%. Si noti che il rapporto ss_e/ss_t poteva anche essere calcolato dall'espressione dell'F-statistic

$$f = \frac{ss_r/k}{ss_e/(n-k-1)} = \frac{ss_t - ss_e}{ss_e}\,\frac{n-k-1}{k} = \left(\frac{ss_t}{ss_e} - 1\right)\frac{n-k-1}{k}$$
$$\Rightarrow \quad \frac{ss_e}{ss_t} = \left(\frac{kf}{n-k-1} + 1\right)^{-1} = \left(\frac{2 \cdot 581.7}{63-2-1} + 1\right)^{-1} = 4.904\%\,.$$

(c) Secondo il modello di Leo,

$$\begin{aligned} \mathbb{E}\left(\texttt{distanza} \mid \texttt{materiale} = \texttt{piombo}\right) &= \beta_0 + \beta_1\,\texttt{tempo}^2 + \beta_2\,\texttt{tempo}^2 \cdot 0\,, \\ \mathbb{E}\left(\texttt{distanza} \mid \texttt{materiale} = \texttt{sughero}\right) &= \beta_0 + \beta_1\,\texttt{tempo}^2 + \beta_2\,\texttt{tempo}^2 \cdot 1\,, \end{aligned} \qquad (*)$$

che si confrontano con la legge oraria $h - g\,t^2/2$. Perciò, l'altezza iniziale h coincide con l'intercetta β_0 per entrambi i materiali. Un $IC_{\beta_0}(95\%)$ è dato da

$$\beta_0 \in \left(\hat{\beta}_0 \pm t_{\frac{1+\gamma}{2}}(n-k-1)\,\text{se}(\hat{\beta}_0)\right) = (59.0124 \pm 2.0003 \cdot 0.8630) = (57.2861\,, 60.7387)$$

con $\hat{\beta}_0 = 59.0124$ e $\text{se}(\hat{\beta}_0) = 0.8630$ dall'output di R e $\gamma = 0.95$ e $t_{\frac{1+\gamma}{2}}(n-k-1) = t_{0.975}(60) = 2.0003$ dalle tavole dele distribuzioni.

(d) Confrontando nuovamente le formule $(*)$ con la legge oraria $h - g\,t^2/2$, troviamo che l'accelerazione di gravità per il `piombo` è $g_p = -2\,\beta_1$, mentre quella per il `sughero` è $g_s = -2\,(\beta_1 + \beta_2)$. La loro differenza è il parametro $g_p - g_s = 2\beta_2$. Per decidere se c'è evidenza che l'accelerazione di gravità dipenda dal tipo di materiale, dobbiamo quindi verificare le ipotesi

$$H_0 : \beta_2 = 0 \quad \text{vs.} \quad H_1 : \beta_2 \neq 0\,.$$

Si può usare direttamente il risultato del T-test sul coefficiente del regressore $\texttt{tempo}^2 \cdot \texttt{materialesughero}$ fornito da R. Il p-value nella summary è pari al 48.7% $\gg$ 5 - 10%, dunque non possiamo rifiutare H_0. Ne concludiamo che nel modello di Leo non c'è alcuna evidenza che l'accelerazione di gravità del piombo sia diversa da quella del sughero.

(e) Abbiamo visto nel punto precedente che l'accelerazione di gravità del `piombo` è $g_p = -2\,\beta_1$. Si richiede perciò di verificare le ipotesi

$$H_0 : -2\,\beta_1 = 9.81 \quad \text{vs.} \quad H_1 : -2\,\beta_1 = 9.81 \qquad \Leftrightarrow \qquad H_0 : \beta_1 = -4.905 \quad \text{vs.} \quad H_1 : \beta_1 \neq -4.905\,.$$

Possiamo farlo con un T-test, in cui regola al livello di significatività α è

$$\text{“rifiuto } H_0 \text{ se } |T_0| > t_{1+\frac{\alpha}{2}}(n-k-1)\text{”}\,,$$

dove $n - k - 1 = 60$ e

$$T_0 = \frac{\hat{\beta}_1 - (-4.905)}{\text{se}(\hat{\beta}_1)}\,.$$

Per trovare il p-value dobbiamo risolvere rispetto ad α l'equazione

$$|t_0| \equiv t_{1+\frac{\alpha}{2}}(60)\,,$$

in cui t_0 è la realizzazione

$$t_0 = \frac{-4.7277 - (-4.905)}{0.2031} = 0.8730\,.$$

Confrontando coi quantili tabulati,

$$t_{0.80}(60) = 0.8477 < t_{1+\frac{\alpha}{2}}(60) = |0.8730| < t_{0.85}(60) = 1.0455 \quad \Leftrightarrow \quad 0.80 < 1 + \frac{\alpha}{2} < 0.85$$
$$\Leftrightarrow \quad 0.30 < \alpha < 0.40\,.$$

Con un p-value compreso fra il 30% e il 40%, non possiamo in alcun modo rifiutare H_0, e concludiamo che i dati del piombo sono in ottimo accordo con il valore $g = 9.81\,\text{m/s}^2$.

(f) In base al modello di Leo, la previsione puntuale per la $\texttt{distanza}^*$ dal suolo dopo il $\texttt{tempo}^* = 2\,\text{s}$ per il $\texttt{materiale}^* = \texttt{sughero}$ è

$$\begin{aligned}\texttt{distanza}^* &= \hat{\beta}_0 + \hat{\beta}_1\,\texttt{tempo}^{*\,2} + \hat{\beta}_2\,\texttt{tempo}^{*\,2} \cdot \texttt{materialesughero}^* \\ &= 59.0124 - 4.7277 \cdot 2^2 + 0.1106 \cdot 2^2 \cdot 1 = 40.544\,.\end{aligned}$$

(g) Le risposte alle domande (c), (d), (e), (f) sono basate sulla validità del modello lineare gaussiano, in quanto è tale modello che permette di calcolare il livello di confidenza dell'intervallo in (c), il p-value dei test in (d), (e) e la densità della statistica pivot per la previsione in (f). Le ipotesi alla base del modello lineare gaussiano sono l'omoschedasticità e la gaussianità dei residui standardizzati. Queste ipotesi sono rispettate dal modello di Leo, in cui i residui non presentano alcun pattern nello scatterplot ($\Rightarrow$ omoschedasticità), si allineano bene alla Q-Q line nel normal Q-Q plot e hanno il p-value del test di Shapiro-Wilk pari al 59.513% e dunque molto elevato ($\Rightarrow$ gaussianità).