Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

IV appello di Statistica per Ingegneria Fisica
24 gennaio 2024

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Esercizio 1. Le Arance Taroccate sono una nuova varietà di agrumi transgenici, il cui DNA è stato modificato in modo che ogni arancia abbia forma perfettamente sferica. È noto che il diametro X (in cm) di un'arancia taroccata qualsiasi è una variabile aleatoria assolutamente continua con densità di probabilità

$$f_X(x) = \begin{cases} \dfrac{3}{10}\left(\dfrac{x}{10}\right)^2 \mathrm{e}^{-\left(\frac{x}{10}\right)^3} & \text{se } x \geq 0\,, \\ 0 & \text{se } x < 0\,. \end{cases}$$

(a) Ricavate la funzione di ripartizione di X.
(Suggerimento: nel calcolo di $\int_0^{\cdots} f_X(u)\,\mathrm{d}u$ sarà utile il cambio della variabile d'integrazione $(u/10)^3 = z$. Prestate attenzione agli estremi d'integrazione.)

Sia $x_{0.8}$ quantile di ordine 80% della densità di X.

(b) Determinate il valore di $x_{0.8}$.

È noto che arance taroccate diverse hanno diametri indipendenti fra loro.

(c) In una cassetta contenente 10 arance taroccate, qual è la probabilità che almeno 2 arance abbiano diametro maggiore del quantile $x_{0.8}$?

Spremendo un'arancia taroccata di diametro X, si ottiene un volume V di succo pari a

$$V = \frac{1}{4}X^3\,.$$

(d) Ricavate la densità della variabile aleatoria V, calcolando dapprima la sua funzione di ripartizione. Se il risultato è un caso notevole, indicate di quale densità si tratta.

(e) Determinate i valori di $\mathbb{E}(V)$ e di $\mathrm{Var}(V)$.
(Suggerimento: se non ci riuscite, continuate assumendo $\mathbb{E}(V) = 182.25\,\mathrm{cm}^3$ e $\mathrm{Var}(V) = 14\,762.25\,\mathrm{cm}^6$.)

Un barista ha comperato 64 arance taroccate, con l'intenzione di spremerle tutte per poi venderne il succo.

(f) Se il barista spreme tutte le 64 arance, con quale probabilità ottiene un volume complessivo di succo maggiore di $13\,000\,\mathrm{cm}^3$ (cioè 13 litri)?

SOLUZIONE.

(a) Usando la definizione

$$F_X(x) = \int_{-\infty}^{x} f_X(u)\,\mathrm{d}u\,,$$

notiamo che $F_X(x) = 0$ se $x < 0$. Se invece $x \geq 0$, si ha

$$F_X(x) = \int_0^x \frac{3}{10}\left(\frac{u}{10}\right)^2 \mathrm{e}^{-\left(\frac{u}{10}\right)^3}\,\mathrm{d}u = \int_0^{\left(\frac{x}{10}\right)^3} \mathrm{e}^{-z}\,\mathrm{d}z = 1 - \mathrm{e}^{-\left(\frac{x}{10}\right)^3}\,.$$

Nel primo integrale abbiamo fatto il cambio di variabile $(u/10)^3 = z$, che implica $(3/10)(u/10)^2\,\mathrm{d}u = \mathrm{d}z$.

(b) Il quantile $x_{0.8}$ è definito dalla relazione $F_X(x_{0.8}) = 0.8$. Poiché $F_X(x) = 0$ se $x < 0$, tale relazione implica in particolare $x_{0.8} \geq 0$. Pertanto,

$$F_X(x_{0.8}) = 0.8 \quad \Leftrightarrow \quad 1 - \mathrm{e}^{-\left(\frac{x_{0.8}}{10}\right)^3} = 0.8 \quad \Leftrightarrow \quad x_{0.8} = -10\sqrt[3]{\ln 0.2} = 11.7190\,.$$

(c) Sia Y la variabile aleatoria che conta quante arance hanno diametro maggiore di $x_{0.8}$ in una cassetta contenente $n = 10$ arance taroccate. La variabile Y conta dunque il numero di successi in una serie di prove di Bernoulli, ciascuna con probabilità di successo pari a $q = \mathbb{P}(X > x_{0.8}) = 1 - F_X(x_{0.8}) = 0.2$. Pertanto, Y ha densità binomiale $B(n, q) = B(10, 0.2)$ e la probabilità richiesta è

$$\begin{aligned}\mathbb{P}(Y \geq 2) = 1 - \mathbb{P}(Y < 2) = 1 - \sum_{k=0}^{1} p_Y(k) &= 1 - \left[1 \cdot 1 \cdot (1-0.2)^{10} + 10 \cdot 0.2 \cdot (1-0.2)^9\right] \\ &= 1 - [0.10737 + 0.26844] = 62.419\%\end{aligned}$$

con

$$p_Y(k) = \binom{n}{k} q^k (1-q)^{n-k} = \binom{10}{k} 0.2^k (1-0.2)^{10-k} \quad k = 0, 1, \ldots, 10\,.$$

(d) Abbiamo

$$F_V(v) = \mathbb{P}(V \leq v) = \mathbb{P}\left(\frac{1}{4} X^3 \leq v\right) = \mathbb{P}\left(X \leq \sqrt[3]{4v}\right) = F_X\left(\sqrt[3]{4v}\right)$$

per ogni $v \in \mathbb{R}$, e quindi in particolare $F_V(v) = 0$ se $v < 0$. Se invece $v \geq 0$,

$$F_V(v) = 1 - \mathrm{e}^{-\left(\frac{\sqrt[3]{4v}}{10}\right)^3} = 1 - \mathrm{e}^{-\frac{v}{250}}\,.$$

La densità f_V di V si ricava derivando F_V come segue

$$f_V(v) = \frac{\mathrm{d}F_V(v)}{\mathrm{d}v} = \begin{cases} \dfrac{1}{250}\,\mathrm{e}^{-\frac{v}{250}} & \text{se } x \geq 0\,, \\ 0 & \text{se } x < 0\,. \end{cases}$$

Si vede dunque che V ha densità esponenziale $V \sim \mathcal{E}(1/250)$.

(e) Leggiamo sul formulario che la densità $\mathcal{E}(\lambda)$ ha valore atteso $1/\lambda$ e varianza $1/\lambda^2$. Pertanto, con $\lambda = 1/250$,

$$\mathbb{E}(V) = 250\,, \qquad \mathrm{Var}(V) = 250^2\,.$$

(f) Sia V_i il volume di succo ottenuto spremendo l'i-esima arancia comperata dal barista. Allora le variabili aleatorie $V_1, V_2, \ldots, V_{64}$ costituiscono un campione aleatorio, con $V_i \sim \mathcal{E}(1/250)$ per quanto visto al punto (d). L'energia consumata complessivamente è la somma $S_{64} = V_1 + V_2 + \ldots + V_{64}$, che per il TLC ($n = 64$ è 'grande') ha approssimativamente densità gaussiana $S_{64} \sim N\big(n\,\mathbb{E}(V_i)\,,\, n\,\mathrm{Var}(V_i)\big)$. La probabilità richiesta è dunque

$$\begin{aligned}\mathbb{P}(S_{64} > 13\,000) &= \mathbb{P}\Bigg(\underbrace{\frac{S_{64} - n\,\mathbb{E}(V_i)}{\sqrt{n\,\mathrm{Var}(V_i)}}}_{\approx N(0,1)} > \frac{13\,000 - 64 \cdot 250}{\sqrt{64 \cdot 250^2}}\Bigg) \simeq 1 - \Phi\left(\frac{13\,000 - 64 \cdot 250}{\sqrt{64 \cdot 250^2}}\right) \\ &= 1 - \Phi(-1.5) = \Phi(1.5) = 0.93319 = 93.319\%\,.\end{aligned}$$

Coi valori di $\mathbb{E}(V)$ e di $\mathrm{Var}(V)$ dati nel suggerimento,

$$\mathbb{P}(S_{64} > 13\,000) = \ldots \simeq 1 - \Phi\left(\frac{13\,000 - 64 \cdot 182.25}{\sqrt{64 \cdot 14762.25}}\right) \simeq 1 - \Phi(1.374) = 1 - 0.91466 = 8.534\%.$$

Esercizio 2. Gilberto de Pippis vuole iscriversi a un corso di laurea in Ingegneria, ma non sa se è migliore il Politecnico di Topolinia o il Politecnico di Paperopoli. Ha dunque deciso che lo stabilirà in base al numero di studenti immatricolati ogni anno, e che sceglierà l'istituto in cui tale numero risulta mediamente maggiore. Dopo aver fatto una ricerca in rete, Gilberto ha raccolto nei vettori `Topolinia` e `Paperopoli` il numero di immatricolati annui nei rispettivi Politecnici. Per Topolinia, in particolare, sono disponibili online tutti i dati sulle immatricolazioni dal 2010 a oggi, mentre per Paperopoli lo sono solo quelli dal 2015 in poi. Gilberto ha quindi elaborato i due vettori con R, ottenendo l'output mostrato qui sotto.

```
> Topolinia
 [1] 6835 6988 7005 7109 6820 7050 6860 6928 7204
[10] 7310 7035 7045 7229 7245
> mean( Topolinia )
[1] 7047.357
> sd( Topolinia )
[1] 157.1362
> shapiro.test( Topolinia )

        Shapiro-Wilk normality test

data:  Topolinia
W = 0.95031, p-value = 0.5656

> qqnorm( Topolinia ); qqline( Topolinia )
>
> Paperopoli
[1] 7119 6753 7049 7332 7121 6783 7171 6592 6824
> mean( Paperopoli )
[1] 6971.556
> sd( Paperopoli )
[1] 242.1064
> shapiro.test( Paperopoli )

        Shapiro-Wilk normality test

data:  Paperopoli
W = 0.94647, p-value = 0.6513

> qqnorm( Paperopoli ); qqline( Paperopoli )
>
```

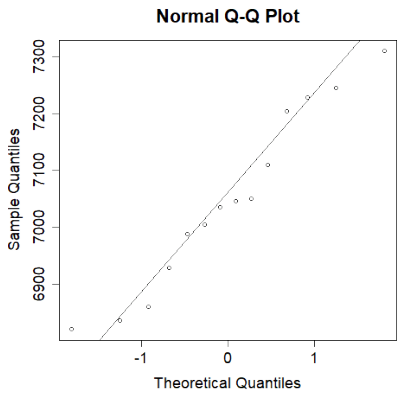

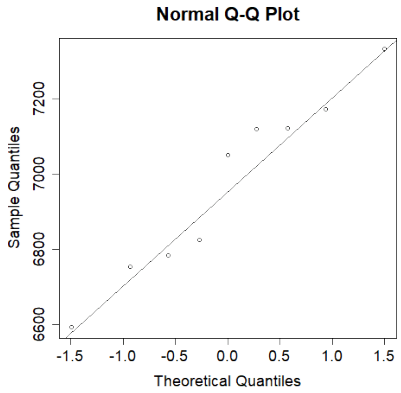

Si può assumere che i due campioni considerati siano indipendenti fra loro.

(a) Verificate con un opportuno test al livello di significatività del 10% se la varianza del numero di immatricolati annui sia la stessa a Topolinia e a Paperopoli.

A parere dello zio Pippo, Gilberto farebbe meglio a iscriversi al Politecnico di Topolinia. Secondo Pippo, infatti, i dati dimostrano che ci sono in media più immatricolati annui a Topolinia e meno a Paperopoli.

(b) Verificate quanto affermato dallo zio Pippo impostando un opportuno test al livello di significatività α. Nel test, l'errore più grave è concludere che in media gli immatricolati annui di Topolinia superano quelli di Paperopoli quando in realtà è vero il contrario.

(c) In base ai dati di Gilberto, come si conclude il test del punto (b) al livello $\alpha = 5\%$?

(d) Fornite un intervallo in cui cade il p-value del test del punto (b). Tale p-value supporta l'opinione dello zio Pippo oppure no?

(e) Quali sono le ipotesi sul campione alla base del test del punto (a)? E quali sono quelle alla base del test del punto (b)? Tali ipotesi sono verificate dai dati? Giustificate la risposta.

SOLUZIONE.

(a) Si richiede di fare un test bilatero al livello di significatività $\alpha = 10\%$ per il rapporto delle varianze σ_X^2 e σ_Y^2 dei due campioni (d'ora in poi, indicheremo con 'X' tutte le quantità relative a Topolinia e con 'Y' quelle relative a Paperopoli). Le ipotesi statistiche da mettere a confronto sono pertanto

$$H_0 : \frac{\sigma_X^2}{\sigma_Y^2} = 1 \qquad \text{vs.} \qquad H_1 : \frac{\sigma_X^2}{\sigma_Y^2} \neq 1\,.$$

La regola di un test al livello α per tali ipotesi è

$$\text{“rifiuto } H_0 \text{ se } F_0 < f_{\frac{\alpha}{2}}(n_X - 1, n_Y - 1) \text{ oppure } F_0 > f_{1-\frac{\alpha}{2}}(n_X - 1, n_Y - 1)\text{”}\,,$$

dove F_0 è la statistica test

$$F_0 := \frac{S_X^2}{S_Y^2}\,,$$

$n_X = 14$ e $n_Y = 9$ sono le numerosità dei due campioni e S_X^2 e S_Y^2 sono le rispettive varianze campionarie. Con le realizzazioni `sd( Topolinia )` $= 157.1362$ e `sd( Paperopoli )` $= 242.1064$ che leggiamo sull'output di R, ricaviamo

$$f_0 = \frac{157.1362^2}{242.1064^2} = 0.42125\,,$$

mentre con $\alpha = 10\%$

$$\begin{aligned} f_{\frac{\alpha}{2}}(n_X - 1, n_Y - 1) &= f_{0.05}(13, 8) = \frac{1}{f_{1-0.05}(8, 13)} = \frac{1}{2.767} = 0.3614 \\ f_{1-\frac{\alpha}{2}}(n_X - 1, n_Y - 1) &= f_{0.95}(13, 8) = 3.259\,. \end{aligned}$$

Poiché

$$0.3614 < f_0 = 0.42125 < 3.259\,,$$

non possiamo rifiutare l'ipotesi nulla che le due varianze siano uguali. Poiché accettiamo H_0, si tratta di una conclusione *debole*.

(b) Indicando con μ_X e μ_Y i valori attesi dei due campioni, si richiede ora di fare un test per le ipotesi

$$H_0 : \mu_X \leq \mu_Y \qquad \text{vs.} \qquad H_1 : \mu_X > \mu_Y\,.$$

Con questa scelta di H_0 e di H_1, infatti, l'errore di I tipo consiste nell'accettare l'ipotesi alternativa $\mu_X > \mu_Y$ quando in realtà è vera l'ipotesi nulla $\mu_X \leq \mu_Y$, ed è proprio questo l'errore più grave per Gilberto. Procedendo con il test al livello di significatività α, dobbiamo quindi applicare la regola

$$\text{“rifiuto } H_0 \text{ se } T_0 > t_{1-\alpha}(n_X + n_Y - 2)\text{”}\,,$$

dove T_0 è la statistica test

$$T_0 := \frac{\bar{X} - \bar{Y}}{\sqrt{S_P^2 \left(\frac{1}{n_X} + \frac{1}{n_Y}\right)}} \qquad \text{con} \qquad S_P^2 := \frac{(n_X - 1)S_X^2 + (n_Y - 1)S_Y^2}{n_X + n_Y - 2}\,.$$

(c) Ricaviamo dai dati

$$s_P^2 = \frac{(14-1)\times 157.1362^2 + (9-1)\times 242.1064^2}{14+9-2} = 37\,615.1086$$
$$t_0 = \frac{7047.357 - 6971.556}{\sqrt{37\,615.1086 \times \left(\frac{1}{14}+\frac{1}{9}\right)}} = 0.9148\,,$$

dove le realizzazioni usate per le medie campionarie sono i valori `mean( Topolinia )` = 7047.357 e `mean( Paperopoli )` = 6971.556. Con $\alpha = 5\%$ abbiamo

$$t_{1-\alpha}(n_X + n_Y - 2) = t_{0.95}(21) = 1.7207\,.$$

Poiché $0.9148 \not> 1.7207$, non possiamo rifiutare H_0 al livello del 5%.

(d) Per determinare il p-value del test del punto (b), dobbiamo imporre l'uguaglianza nella regola di rifiuto e risolvere così rispetto a α l'equazione

$$t_0 = t_{1-\alpha}(21)\,.$$

Sulle tavole delle distribuzioni vediamo che

$$t_{0.8}(21) = 0.8591 < t_0 = 0.9148 < t_{0.85}(21) = 1.0627$$

e quindi

$$0.8 < 1-\alpha < 0.85 \quad \Leftrightarrow \quad 0.15 < \alpha < 0.20\,.$$

Con un p-value compreso fra il 15% e uil 20%, siamo ben lontani dalla soglia del 5% sotto la quale usualmente si rifiuta H_0. Perciò, dobbiamo accettare H_0 e concludere che l'opinione dello zio Pippo NON è supportata dai dati di Gilberto (conclusione *debole*).

(e) Alla base sia del test sulle varianze del punto (a) sia del test sui valori attesi del punto (b) c'è l'*indipendenza* e la *gaussianità* di entrambi i campioni $X_1, \ldots, X_{14}$ e $Y_1, \ldots, Y_9$. Assumere l'indipendenza è ragionevole e comunque è specificato nel testo. Per quanto riguarda invece la gaussianità, non si può escluderla in quanto entrambi i normal Q-Q plot mostrano una buona aderenza dei quantili empirici dei dati a quelli teorici della normale standard e inoltre il p-value del test di Shapiro-Wilk è elevato per entrambi i campioni (come si legge dall'output del comando `shapiro.test` nella console di R, $p\text{-value}_X = 56.56\%$ e $p\text{-value}_Y = 65.13\%$, percentuali ben maggiori delle usuali soglie del 5-10%). Per svolgere il T-test, infine, è anche essenziale poter assumere l'*uguaglianza delle varianze* dei due campioni. Tale ipotesi risulta ammissibile in quanto è già stata verificata al punto (a).

Esercizio 3. La ACME è una grande azienda che produce componenti elettroniche. I suoi tecnici hanno recentemente sviluppato un nuovo tipo di processore ancora più potente dei precedenti e ora, prima di immetterlo sul mercato, devono essere sicuri che non si surriscaldi troppo durante il funzionamento. Ai tecnici in particolare interessa capire qual è la relazione fra la `temperatura` del processore (in °C), la sua `frequenza` di clock (in GHz) e il numero dei `processi` in esecuzione. Vengono quindi effettuate prove per 73 differenti valori delle quantità precedenti, ottenendo i dati rappresentati nello scatterplot qui sotto.

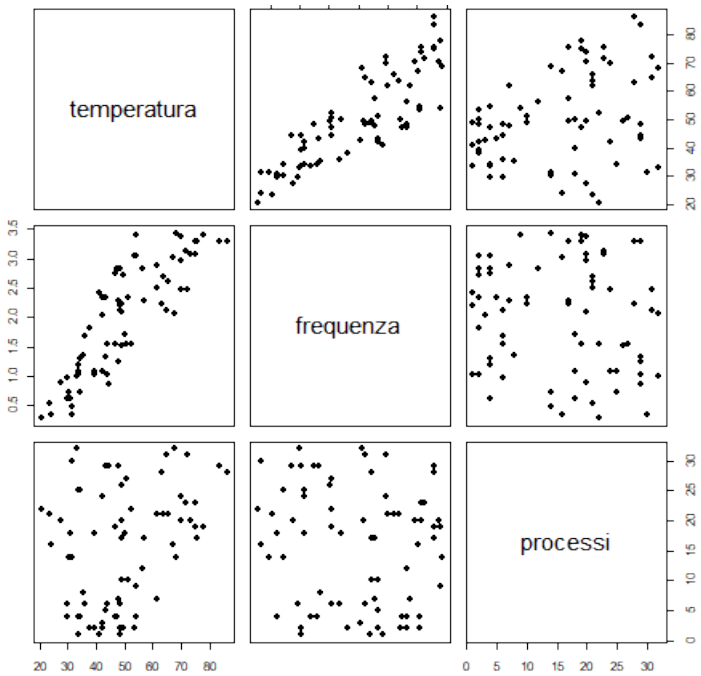

I tecnici cercano di descrivere la relazione fra questi dati utilizzando tre diversi modelli di regressione lineare. Le pagine seguenti illustrano l'output di R e la diagnostica dei residui ottenuti con ciascuno dei tre modelli.

(a) Scrivete la relazione fra le variabili `temperatura`, `frequenza` e `processi` ipotizzata in ciascun modello.

(b) Sono presenti modelli che non spiegano a sufficienza la variabilità dei dati? Se sì, quali sono e perché?

(c) Indicate le ipotesi alla base del modello lineare gaussiano. Quali modelli le rispettano?

(d) Individuate gli eventuali regressori non significativi in ciascun modello, giustificando la risposta.

(e) Qual è il modello migliore fra i tre proposti? Motivate la vostra scelta.

La ACME distribuirà il nuovo processore montandolo su schede madri che hanno una frequenza di clock costante e pari a 3.00 GHz. I tecnici devono quindi capire quale temperatura raggiunge il processore quando la sua frequenza mantiene questo valore fissato, mentre varia soltanto il numero dei processi in esecuzione.

(f) Sia δ l'incremento di temperatura atteso quando il numero dei processi aumenta di una singola unità, mentre la frequenza rimane costante e pari a 3.00 GHz. Scrivete δ come opportuna combinazione lineare dei coefficienti del modello migliore scelto al punto (e). Determinate poi in base ai dati un intervallo di confidenza bilatero per δ al livello di confidenza del 90%.

(g) Utilizzando sempre il modello migliore scelto in (e), fornite una previsione puntuale per la temperatura che si osserva in un processore che esegue 32 processi alla frequenza di clock di 3.00 GHz.

```
Call:
lm(formula = temperatura ~ frequenza + processi + frequenza:processi)

Residuals:
    Min      1Q  Median      3Q     Max 
-8.2461 -2.5224  0.4407  2.4018  7.5265 

Coefficients:
                   Estimate Std. Error t value Pr(>|t|)    
(Intercept)        23.53279    2.35408   9.997 4.73e-15 ***
frequenza           7.99624    1.08109   7.396 2.53e-10 ***
processi           -0.15020    0.11754  -1.278    0.206    
frequenza:processi  0.42607    0.05607   7.598 1.08e-10 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.759 on 69 degrees of freedom
Multiple R-squared:  0.9457,	Adjusted R-squared:  0.9433 
F-statistic: 400.6 on 3 and 69 DF,  p-value: < 2.2e-16
```

Summary Modello 1

```
Call:
lm(formula = temperatura ~ frequenza + frequenza:processi)

Residuals:
    Min      1Q  Median      3Q     Max 
-8.8590 -2.2477  0.3315  2.3699  8.2002 

Coefficients:
                   Estimate Std. Error t value Pr(>|t|)    
(Intercept)        20.83793    1.05076   19.83   <2e-16 ***
frequenza           9.16648    0.57711   15.88   <2e-16 ***
frequenza:processi  0.35997    0.02173   16.56   <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 3.776 on 70 degrees of freedom
Multiple R-squared:  0.9444,	Adjusted R-squared:  0.9428 
F-statistic: 594.7 on 2 and 70 DF,  p-value: < 2.2e-16
```

Summary Modello 2

```
Call:
lm(formula = temperatura ~ processi)

Residuals:
    Min      1Q  Median      3Q     Max 
-32.464 -10.587  -0.978  10.239  30.191 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  42.1042     3.3601  12.530  < 2e-16 ***
processi      0.4991     0.1810   2.757  0.00741 ** 
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 15.11 on 71 degrees of freedom
Multiple R-squared:  0.0967,	Adjusted R-squared:  0.08398 
F-statistic: 7.601 on 1 and 71 DF,  p-value: 0.00741
```

Summary Modello 3

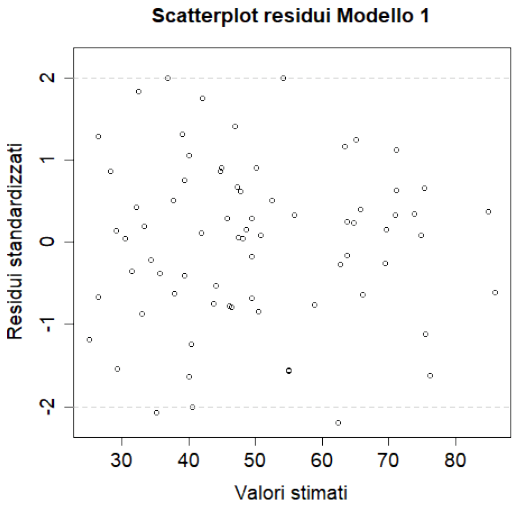
Scatterplot residui Modello 1
Residui standardizzati
Valori stimati

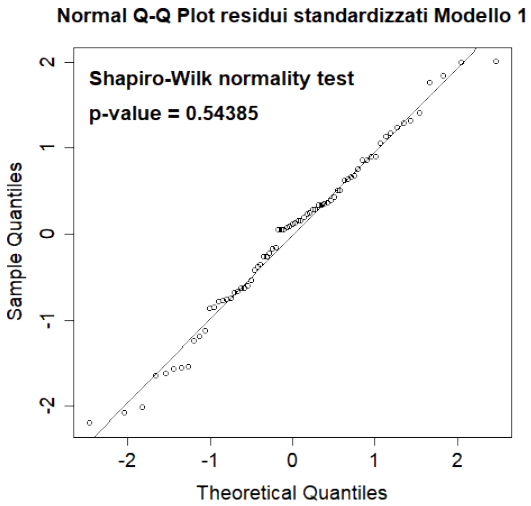
Normal Q-Q Plot residui standardizzati Modello 1
Shapiro-Wilk normality test
p-value = 0.54385
Sample Quantiles
Theoretical Quantiles

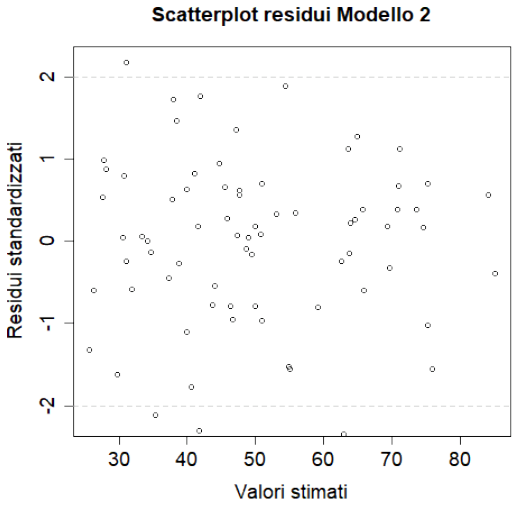
Scatterplot residui Modello 2
Residui standardizzati
Valori stimati

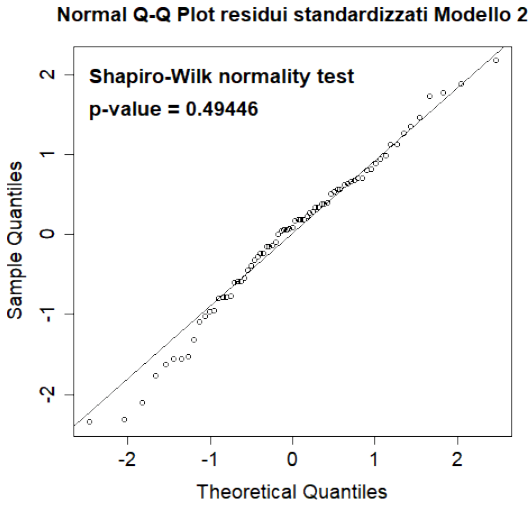
Normal Q-Q Plot residui standardizzati Modello 2
Shapiro-Wilk normality test
p-value = 0.49446
Sample Quantiles
Theoretical Quantiles

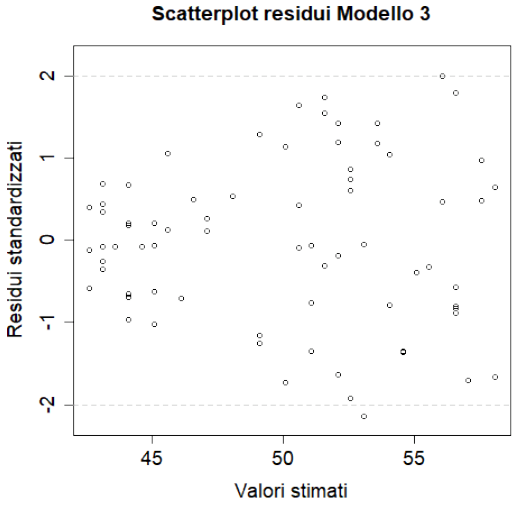
Scatterplot residui Modello 3
Residui standardizzati
Valori stimati

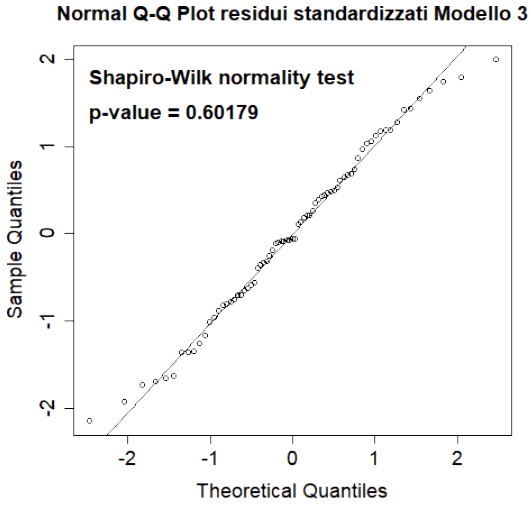
Normal Q-Q Plot residui standardizzati Modello 3
Shapiro-Wilk normality test
p-value = 0.60179
Sample Quantiles
Theoretical Quantiles

SOLUZIONE.

(a) Modello 1: $\texttt{temperatura}_i = \beta_0 + \beta_1 \texttt{frequenza}_i + \beta_2 \texttt{processi}_i + \beta_3 \texttt{frequenza}_i \cdot \texttt{processi}_i + E_i$

Modello 2: $\texttt{temperatura}_i = \beta_0 + \beta_1 \texttt{frequenza}_i + \beta_2 \texttt{frequenza}_i \cdot \texttt{processi}_i + E_i$

Modello 3: $\texttt{temperatura}_i = \beta_0 + \beta_1 \texttt{processi}_i + E_i$

dove $E_1, \ldots, E_{73}$ sono i.i.d., $E_i \sim N(0, \sigma^2)$ e σ^2 è incognita.

(b) La percentuale di variabilità dei dati spiegata da un modello è il suo coefficiente di determinazione r^2. Nel caso di modelli di regressione multipla come quelli in esame, tuttavia, è preferibile confrontare i valori r^2_{adj}, che sono 'aggiustati' penalizzando l'aggiunta di un numero eccessivo di predittori. Si ha

$$r^2_{\text{adj},1} = 94.33\%\,, \qquad r^2_{\text{adj},2} = 94.28\%\,, \qquad r^2_{\text{adj},3} = 8.398\%\,,$$

valori che soltanto per i Modelli 1 e 2 sono ben al di sopra dell'usuale limite di accettabilità dell'80-81%. Per il Modello 3, invece, il valore di r^2_{adj} è estremamente basso e insoddisfacente. Perciò, il Modello 3 è l'unico dei tre che non spiega a sufficienza la variabilità dei dati.

(c) Le ipotesi alla base del modello lineare gaussiano sono l'omoschedasticità e la gaussianità dei residui standardizzati. Dai grafici di diagnostica dei residui si vede che entrambe queste ipotesi sono soddisfatte da tutti e tre i modelli. In ogni modello, infatti, lo scatterplot dei residui standardizzati non mostra particolari pattern ($\Rightarrow$ omoschedasticità), eccetto forse un lieve restringimento verso sinistra nel caso del Modello 3. Inoltre, i residui sono ben allineati alla Q-Q line in tutti i normal Q-Q plot, forniscono sempre p-value molto elevato nei test di Shapiro-Wilk e, come si vede ancora dagli scatterplot, soltanto per il 5% circa fuoriescono dall'intervallo $[-2, 2]$ in tuti i modelli ($\Rightarrow$ gaussianità).

(d) I regressori non significativi sono quelli che presentano p-value elevati nei T-test corrispondenti. Vediamo pertanto che nel Modello 1 il solo regressore `processi` è non significativo ($p\text{-value}_{\texttt{processi}} = 20.6\% >$ 5-10%), mentre nei Modelli 2 e 3 tutti i regressori sono significativi.

(e) Il migliore dei tre modelli proposti è indubbiamente il Modello 2. Come gli altri due modelli, infatti, soddisfa le ipotesi alla base del modello lineare gaussiano, Al contrario del Modello 1, inoltre, tutti i regressori del Modello 2 sono significativi. Al contrario del Modello 3, infine, il Modello 2 spiega molto bene la variabilità dei dati.

(f) Usando il Modello 2, abbiamo

$$\begin{aligned}
\mathbb{E}\left(\texttt{temperatura}\right) &= \mathbb{E}\left(\beta_0 + \beta_1 \texttt{frequenza} + \beta_2 \texttt{frequenza} \cdot \texttt{processi} + E\right) \\
&= \beta_0 + \beta_1 \texttt{frequenza} + \beta_2 \texttt{frequenza} \cdot \texttt{processi} + \mathbb{E}\left(E\right) \\
&= \beta_0 + \beta_1 \texttt{frequenza} + \beta_2 \texttt{frequenza} \cdot \texttt{processi}
\end{aligned}$$

in quanto $\mathbb{E}\left(E\right) = 0$. Perciò,

$$\begin{aligned}
\delta &= \mathbb{E}\left(\texttt{temperatura} \mid \texttt{frequenza} = 3.00,\, \texttt{processi} = x + 1\right) + \\
&\quad - \mathbb{E}\left(\texttt{temperatura} \mid \texttt{frequenza} = 3.00,\, \texttt{processi} = x\right) \\
&= \beta_0 + \beta_1 \times 3.00 + \beta_2 \times 3.00 \times (x + 1) - (\beta_0 + \beta_1 \times 3.00 + \beta_2 \times 3.00 \cdot x) \\
&= \beta_2 \times 3.00\,.
\end{aligned}$$

Per ricavare un $IC_\delta(90\%)$, possiamo quindi trasformare un $IC_{\beta_2}(90\%)$ usando la relazione $\delta = \beta_2 \times 3.00$. Sul formulario troviamo che un $IC_{\beta_2}(\gamma)$ bilatero è dato da

$$\beta_2 \in \left(\hat{\beta}_2 \pm t_{\frac{1+\gamma}{2}}(n-k-1)\,\mathrm{se}(\hat{\beta}_2)\right) .$$

Con $n = 73$ punti, $k = 2$ regressori e le stime $\hat{\beta}_2 = 0.35997$, $\mathrm{se}(\hat{\beta}_2) = 0.02173$ fornite dall'output di R, al livello $\gamma = 0.90$ abbiamo

$$\beta_2 \in (0.35997 \pm t_{0.95}(70) \times 0.02173) = (0.35997 \pm 1.6669 \times 0.02173) = (0.32375\,,\,0.39619)\,.$$

e quindi

$$\delta \in (0.32375 \times 3.00\,,\,0.39619 \times 3.00) = (0.97124\,,\,1.18858)\,.$$

(g) Utilizzando i valori $\texttt{frequenza}^* = 3.00$ e $\texttt{processi}^* = 32$, il Modello 2 fornisce la previsione puntuale

$$\begin{aligned}\texttt{temperatura}^* &= \hat{\beta}_0 + \hat{\beta}_1\,\texttt{frequenza}^* + \hat{\beta}_2\texttt{frequenza}^* \cdot \texttt{processi}^* \\ &= 20.83793 + 9.16640 \times 3.00 + 0.35997 \times 3.00 \times 32 = 82.89449\,.\end{aligned}$$