Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

I Appello di Statistica per Ingegneria Fisica — Prova scritta del 21/01/2025

Cognome

Nome

Matricola o Codice Persona	N.

Questo testo va consegnato insieme ai fogli con le soluzioni.

Su tutti i fogli che consegnerà, lo studente indichi il proprio cognome, nome e numero di matricola.
Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Tempo: 2h 30min

Esercizio 1. Ogni puntata del programma televisivo "Propaganda Live", condotto da Zoro, va in onda il venerdì sera ed inizia ad un'ora X, che è una variabile aleatoria gaussiana centrata intorno alle ore nove e mezza ($= 9.5$). Inoltre, il 90% delle puntate inizia dopo le ore nove ($= 9$). Infine, le ore d'inizio di puntate diverse sono tutte indipendenti tra loro.

(a) Determinate la varianza di X.

Tra quest'anno e il prossimo, il giornalista Paolo, ospite fisso della trasmissione, dovrà partecipare a 70 puntate del programma. Poiché è una persona puntuale e ci tiene molto ad arrivare in trasmissione prima del conduttore Zoro, ha deciso che tutti i venerdì sera si presenterà nello studio televisivo esattamente alle ore nove ($= 9$).

(b) In questo modo, qual è la probabilità che non perda mai l'inizio di una puntata?

(c) E qual è invece la probabilità (eventualmente calcolata in maniera approssimata) che ne perda al massimo 9?

Anche l'ora a cui finisce una qualsiasi delle puntate della trasmissione è una variabile aleatoria Y gaussiana e con la stessa varianza di X. Tuttavia, Y è centrata intorno a mezzanotte e mezza ($= 12.5$) anziché alle nove e mezza ($= 9.5$). Inoltre possiamo ritenere indipendenti X e Y.

(d) Sia D la durata di una puntata. Calcolare media, moda, mediana e varianza di D.

(e) Qual è la probabilità che una puntata duri più di tre ore?

(f) Qual è la probabilità che duri esattamente 3 ore?

Soluzione 1. (a) Ponendo $\mu = \mathbb{E}[X] = 9.5$ e $\sigma^2 = \mathrm{Var}(X)$, sappiamo che

$$0.90 \equiv \mathbb{P}(X > 9) = \mathbb{P}\left(\underbrace{\frac{X-\mu}{\sigma}}_{\sim N(0,1)} > \frac{9-9.5}{\sigma}\right) = 1 - \Phi\left(\frac{9-9.5}{\sigma}\right) = \Phi\left(\frac{0.5}{\sigma}\right)$$

$$\Rightarrow \quad \frac{0.5}{\sigma} = z_{0.90} = 1.28 \quad \Rightarrow \quad \sigma = \frac{0.5}{1.28} = 0.390625$$

$$\Rightarrow \quad \mathrm{Var}(X) = 0.390625^2 = 0.152588.$$

(b) Se chiamiamo S = "numero di trasmissioni perse da Paolo", allora $S \sim B(70, (1-0.90)) = B(70, 0.10)$, e la probabilità cercata è

$$\mathbb{P}(S = 0) = \binom{70}{0}(0.10)^0(1-0.10)^{70-0} = 0.90^{70} = 0.000626\,.$$

(c) Ora vogliamo calcolare

$$\mathbb{P}(S \leq 9) = \mathbb{P}(S \leq 9.5) = \mathbb{P}\left(\underbrace{\frac{S - \mathbb{E}[S]}{\sqrt{\mathrm{Var}(S)}}}_{\substack{\approx N(0,1) \\ \text{per il TLC}}} \leq \frac{9.5 - 70 \cdot 0.10}{\sqrt{70 \cdot 0.10 \cdot (1 - 0.10)}} \right)$$

$$\simeq \Phi\left(\frac{9.5 - 70 \cdot 0.10}{\sqrt{70 \cdot 0.10 \cdot (1 - 0.10)}} \right) = \Phi(0.996) \simeq 0.84.$$

Senza correzione di continuità:

$$\mathbb{P}(S \leq 9) = \mathbb{P}\left(\frac{S - \mathbb{E}[S]}{\sqrt{S}} \leq \frac{9 - 70 \cdot 0.10}{\sqrt{70 \cdot 0.10 \cdot (1 - 0.10)}} \right)$$

$$\simeq \Phi\left(\frac{9 - 70 \cdot 0.10}{\sqrt{70 \cdot 0.10 \cdot (1 - 0.10)}} \right) = \Phi(0.796) \simeq 0.785\,.$$

(d) Abbiamo

$$D = Y - X$$

e quindi

$$\mathbb{E}[D] = \mathbb{E}[Y] - \mathbb{E}[X] = 12.5 - 9.5 = 3$$

$$\mathrm{Var}(D) \overset{\text{indip.}}{=} \mathrm{Var}(Y) + \mathrm{Var}(X) \simeq 0.152588 + 0.152588 = 0.305176$$

Poiché X e Y sono gaussiane e indipendenti, abbiamo che D é anch'essa distribuita come una gaussiana, quindi

$$\mathrm{Moda}(D) = \mathrm{Mediana}(D) = \mathbb{E}[D] = 3.$$

(e) Poiché X e Y sono gaussiane e indipendenti, abbiamo

$$D \sim N(\mathbb{E}[D], \mathrm{Var}(D)) = N(3, 0.305176)\,.$$

Pertanto,

$$\mathbb{P}(D > 3) = \mathbb{P}(D > \mathbb{E}[D]) = \frac{1}{2} \qquad \text{perché } N(\mathbb{E}[D], \mathrm{Var}(D)) \text{ è simmetrica intorno a } \mathbb{E}[D]\,.$$

(f) Dato che D é una variabile aleatoria assolutamente continua, si ha

$$\mathbb{P}(D = 3) = 0.$$

Esercizio 2. La Farmaceutica XYZ è una grande azienda che produce un farmaco (in compresse) chiamato ActivePlus, utilizzato per il trattamento di una specifica condizione medica. La concentrazione di un principio attivo nel farmaco è critica per il suo funzionamento e deve essere conforme alle normative sanitarie. La legge stabilisce che la concentrazione media del principio attivo non deve superare il valore limite di 1 mg per compressa. Per commercializzare il farmaco, la Farmaceutica XYZ deve dimostrare che la concentrazione media nelle sue compresse è inferiore a questo limite. Viene quindi analizzato un campione di 100 compresse. Le concentrazioni rilevate (in mg per compressa) sono raccolte nel vettore `ActivePlus` ed elaborate con R come riportato nella pagina seguente (vedi Figura 1).

(a) Impostate un test al livello di significatività α per decidere se c'è evidenza dai dati che il farmaco ActivePlus rispetti i limiti di legge.

- Motivate opportunamente la scelta del test sulla base dei dati a disposizione.
- Scrivete le ipotesi nulla e alternativa e la regola di rifiuto del test al livello α. Ovviamente, l'errore più grave consiste nel ritenere che il farmaco sia conforme alla legge quando in realtà esso la viola.

(b) Determinate il p-value del test del punto (a). In base al valore trovato, qual è la vostra conclusione?

La Farmaceutica XYZ produce anche una versione light del farmaco, chiamato MedActive. Si sono fatte le stesse analisi pure su questa versione, raccogliendo i risultati nel vettore `MedActive`. I nuovi dati elaborati con R si trovano nella Figura 2 della pagina seguente.

(c) Impostate un test al livello di significatività 1% per stabilire se c'è evidenza dai dati che il farmaco MedActive abbia una concentrazione media del principio attivo minore del farmaco ActivePlus. Motivate opportunamente la scelta del test sulla base dei dati a disposizione.

```
> ActivePlus
  [1] 0.26 0.24 1.39 1.31 0.30 0.25 0.27 0.24 0.24 0.74 0.36 0.54 0.26 1.03
 [15] 0.95 0.32 0.32 0.27 0.24 0.39 0.53 0.27 0.32 1.12 0.97 0.31 0.75 0.24
 [29] 0.27 0.24 0.70 1.36 0.88 0.89 0.37 0.26 0.42 0.41 0.36 0.29 1.13 0.28
 [43] 0.58 0.45 0.24 0.42 0.24 1.43 0.52 1.40 0.24 1.33 0.49 1.50 0.98 1.15
 [57] 1.16 1.11 0.80 0.35 1.20 1.12 1.28 1.67 1.72 1.27 1.68 1.25 1.71 1.40
 [71] 1.56 1.72 1.47 1.29 1.34 1.43 1.68 1.03 1.67 1.44 1.74 1.53 1.58 1.67
 [85] 1.72 1.59 1.62 1.41 1.40 1.62 1.47 1.60 1.43 1.52 1.07 1.22 0.74 1.61
 [99] 1.58 0.63
> length(ActivePlus)
[1] 100
> mean(ActivePlus)
[1] 0.9436
> sd(ActivePlus)
[1] 0.5410045
> shapiro.test(ActivePlus)

        Shapiro-Wilk normality test

data:  ActivePlus
W = 0.87676, p-value = 1.327e-07

> qqnorm(ActivePlus)
> qqline(ActivePlus)
```

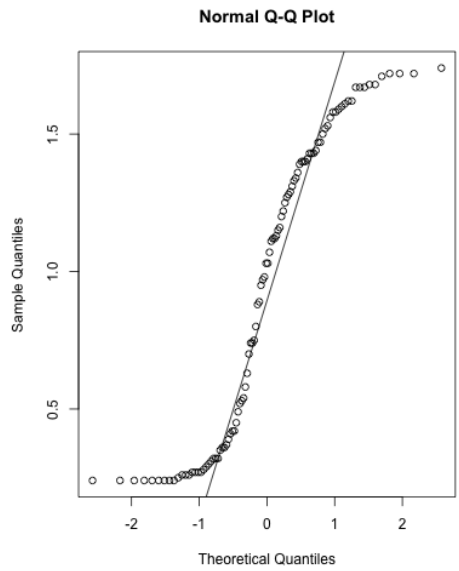

Figura 1: Console di R e relativo output per il farmaco ActivePlus

---

```
>
> MedActive
 [1] 0.95 0.38 0.65 0.26 1.20 1.19 0.85 0.37 0.87 0.84 0.25 0.61 1.22 0.20
[15] 0.86 0.75 0.77 0.46 1.52 0.21 0.65 0.96 0.33 0.67 0.68 1.33 0.91 0.43
[29] 0.74 0.70 0.76 0.64 0.83 1.15 0.80 1.20 1.03 0.71 0.50 0.66 0.40 0.76
[43] 0.84 0.96 0.61 0.55 1.16 0.27 0.11 0.89 1.46 0.99 0.52 1.23 0.28 0.41
[57] 1.08 1.00 0.91 0.89
> length(MedActive)
[1] 60
> mean(MedActive)
[1] 0.7568333
> sd(MedActive)
[1] 0.3312661
> shapiro.test(MedActive)

        Shapiro-Wilk normality test

data:  MedActive
W = 0.9842, p-value = 0.6283

> qqnorm(MedActive)
> qqline(MedActive)
>
```

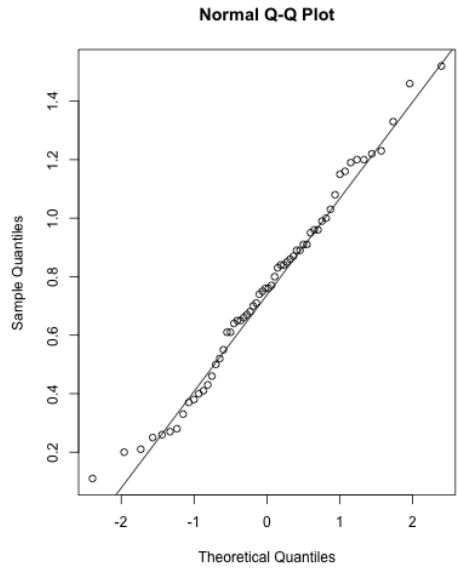

Figura 2: Console di R e relativo output per il farmaco MedActive

Soluzione 2. Il vettore `ActivePlus` contiene una realizzazione da un campione aleatorio $X_1, \ldots, X_n$ con $n = 100$. La densità delle X_i è incognita e sicuramente non gaussiana, come si vede dalla Figura 1 e dal p-value del test di Shapiro-Wilk. Indichiamo con $\mu_X = \mathbb{E}[X_i]$ il valore atteso della popolazione.

(a) Si tratta di impostare un test di livello α per le ipotesi statistiche

$$H_0 : \mu_X \geq 1 := \mu_0 \qquad \text{vs.} \qquad H_1 : \mu_X < \mu_0 \,.$$

Si noti che con questa scelta, l'errore più grave (cioè quello di primo tipo) consiste nel ritenere il farmaco conforme alla legge (equivalentemente: accettare H_1, rifiutando H_0 di conseguenza) quando in realtà esso lo viola (equivalentemente: quando in realtà H_0 è vera). Siccome abbiamo già osservato che le X_i non sono gaussiane, necessariamente dovremo utilizzare un test asintotico; in questo caso possiamo farlo, perché $n = 100$ è un valore sufficientemente grande. Sul formulario, troviamo che la regola di un test al livello approssimativamente pari ad α è dunque

$$\text{“ rifiuto } H_0 \text{ se e solo se } Z_0 := \frac{\overline{X} - \mu_0}{S_X}\sqrt{n} < -z_{1-\alpha} \text{”} \,.$$

(b) Con i dati a disposizione, risulta

$$z_0 = \frac{\overline{x} - \mu_0}{s_X}\sqrt{n} = \frac{0.9436 - 1}{0.5410045}\sqrt{100} = -1.042505 \,.$$

Il p-value si calcola dunque risolvendo in α l'equazione

$$\begin{aligned} z_0 \equiv -z_{1-\alpha} \quad &\Leftrightarrow \quad 1.042505 = z_{1-\alpha} \quad \Leftrightarrow \quad \Phi(1.042505) = \Phi(z_{1-\alpha}) = 1 - \alpha \\ &\Leftrightarrow \quad \alpha = 1 - \Phi(1.042505) = 1 - 0.85083 = 0.14917 \,. \end{aligned}$$

Un p-value $\simeq 15\%$ è piuttosto alto, maggiore degli usuali livelli di significatività dell'1%, 5% e 10%. In altre parole, non si può rifiutare H_0 ai livelli di significatività dell'1%, del 5% e del 10%, e non c'è dunque nessuna evidenza contro l'ipotesi H_0 che il farmaco ActivePlus violi il limite di legge.

Ora invece abbiamo a disposizione un secondo campione aleatorio $Y_1, \ldots, Y_m$ relativo alla concentrazione media del principio attivo del farmaco MedActive, indipendente da quello considerato in precedenza. Si noti che la numerosità di quest'ultimo campione è $m =$ `length(MedActive)` $= 60$. Dalla Figura 2 (sia dal normal Q-Q plot, sia dal p-value del test di Shapio-Wilk) si vede che $Y_i \sim N(\mu_Y, \sigma_Y^2)$ con varianza σ_Y^2 incognita.

(c) Si tratta di impostare un test di livello $\alpha = 1\%$ per la differenza dei valori attesi $\mu_X - \mu_Y$:

$$H_0 : \mu_X \leq \mu_Y \quad (\Leftrightarrow \mu_X - \mu_Y \leq 0) \qquad \text{vs.} \qquad H_1 : \mu_X > \mu_Y \quad (\Leftrightarrow \mu_X - \mu_Y > 0) \,.$$

Si noti che in H_1 abbiamo messo l'affermazione per cui cerchiamo evidenza dai dati.

Siccome il primo campione $X_1, \ldots, X_n$ non è gaussiano, ma $n = 100$ e $m = 60$ (entrambi maggiori di 50) sono sufficientemente grandi, applicheremo un test asintotico sulla differenza delle medie di due campioni indipendenti. La regola di un tale test al livello approssimativamente pari ad α è

$$\text{“ rifiuto } H_0 \text{ se e solo se } Z_0 := \frac{\overline{X} - \overline{Y}}{\sqrt{\frac{S_X^2}{n} + \frac{S_Y^2}{m}}} > z_{1-\alpha} \text{”}$$

e con $\alpha = 1\%$ si ha

$$z_{1-\alpha} = z_{0.99} = 2.33 \,.$$

Con i dati a disposizione risulta

$$z_0 = \frac{\overline{x} - \overline{y}}{\sqrt{\frac{s_X^2}{n} + \frac{s_Y^2}{m}}} = \frac{0.9436 - 0.7568333}{\sqrt{\frac{0.5410045^2}{100} + \frac{0.3312661^2}{60}}} = 2.708240 \,.$$

Poiché $z_0 = 2.708240 > 2.33 = z_{1-\alpha}$, dobbiamo rifiutare H_0 a livello di significatività del 1% e accettare H_1.

Esercizio 3. Lo chef stellato Star è noto per la sua capacità di trasformare piatti semplici in vere opere d'arte gastronomiche. Tra le sue specialità c'è una vellutata di verdure particolarmente apprezzata per la sua consistenza perfetta. Sebbene gli aromi e la qualità degli ingredienti come le verdure fresche e le erbe aromatiche siano fondamentali per il sapore, lo chef ha stabilito che non influiscono in modo significativo sulla densità della vellutata. Per questo motivo, ha deciso di concentrarsi su due ingredienti chiave che potrebbero influenzare questa caratteristica: latte e fecola di patate. Per affinare ulteriormente la sua ricetta e garantire una consistenza ideale, lo chef Star ha condotto una serie di esperimenti in cucina. Ha preparato la vellutata 25 volte, variando le percentuali di latte (L) e fecola di patate (F) utilizzate, e ha misurato la densità finale (D) della vellutata ogni volta.
Nella figura sottostante è riportato lo scatterplot di densità, latte e fecola.

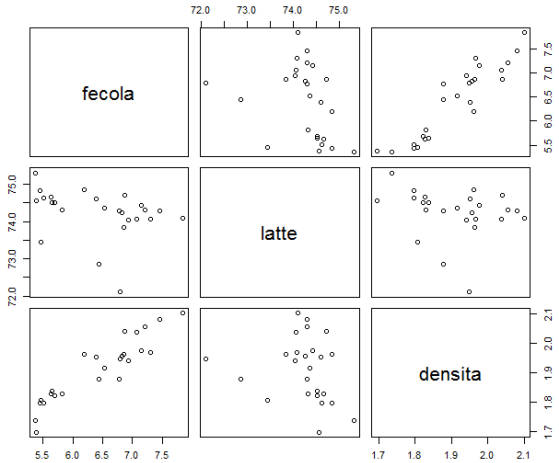

Figura 3: Scatterplot delle variabili

Per studiare la relazione tra densità, latte e fecola, lo chef Star imposta un modello empirico lineare gaussiano con responso la densità Y e predittori F e L senza interazione tra i regressori. Imposta successivamente anche due modelli lineari semplici, uno utilizzando come unico predittore la quantità di fecola utilizzata, mentre l'altro utilizzando la quantità di latte impiegata.

(a) Scrivere la relazione tra le variabili ipotizzata dai tre modelli.

I risultati della stima dei modelli sono riportati in Figura 4 e i grafici relativi ai residui in Figura 5.

(b) I tre modelli sono globalmente significativi?

(c) Quali dei tre modelli spiegano meglio la variabilità della risposta?

(d) Quali dei tre modelli hanno residui normali? Quali dei tre modelli hanno residui omoschedastici?

Lo chef Star vuole stabilire quale tra i tre modelli va ritenuto il migliore. In particolare, partendo dal modello completo, vuole decidere se il regressore latte è significativo.

(e) Impostare un opportuno test per stabilire se nel modello completo il regressore latte sia o meno significativo. Scrivere le ipotesi nulla e alternativa e la statistica test utilizzata. Sulla base dell'output in Figura 4 cosa possiamo concludere?

Sulla base delle considerazioni fatte nei punti precedenti indicare quale modello è il migliore tra i tre proposti. Per il punto successivo si utilizzi il modello scelto.

(f) Impostare un opportuno test per stabilire se il coefficiente β relativo al regressore fecola sia maggiore di 0.1. Calcolarne il p-value. Cosa si può concludere?

```
Call:
lm(formula = densita ~ fecola + latte)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.071671 -0.023113  0.002325  0.023381  0.105326 

Coefficients:
             Estimate Std. Error t value Pr(>|t|)    
(Intercept)  1.451235   0.707170   2.052   0.0522 .  
fecola       0.101785   0.012958   7.855 7.98e-08 ***
latte       -0.002676   0.009352  -0.286   0.7775    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.03976 on 22 degrees of freedom
Multiple R-squared:  0.8082,	Adjusted R-squared:  0.7908 
F-statistic: 46.36 on 2 and 22 DF,  p-value: 1.29e-08
```

```
Call:
lm(formula = densita ~ fecola)

Residuals:
      Min        1Q    Median        3Q       Max 
-0.069798 -0.028688  0.001795  0.019966  0.106476 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  1.24990    0.06834  18.289 3.36e-15 ***
fecola       0.10384    0.01057   9.823 1.07e-09 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.03896 on 23 degrees of freedom
Multiple R-squared:  0.8075,	Adjusted R-squared:  0.7991 
F-statistic: 96.49 on 1 and 23 DF,  p-value: 1.07e-09
```

```
Call:
lm(formula = densita ~ latte)

Residuals:
     Min       1Q   Median       3Q      Max 
-0.12947 -0.05620  0.01569  0.05750  0.15172 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  4.96613    1.04465   4.754  8.6e-05 ***
latte       -0.04337    0.01485  -2.919  0.00772 ** 
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.07585 on 23 degrees of freedom
Multiple R-squared:  0.2704,	Adjusted R-squared:  0.2386 
F-statistic: 8.522 on 1 and 23 DF,  p-value: 0.007718
```

Figura 4: Summary dei modelli

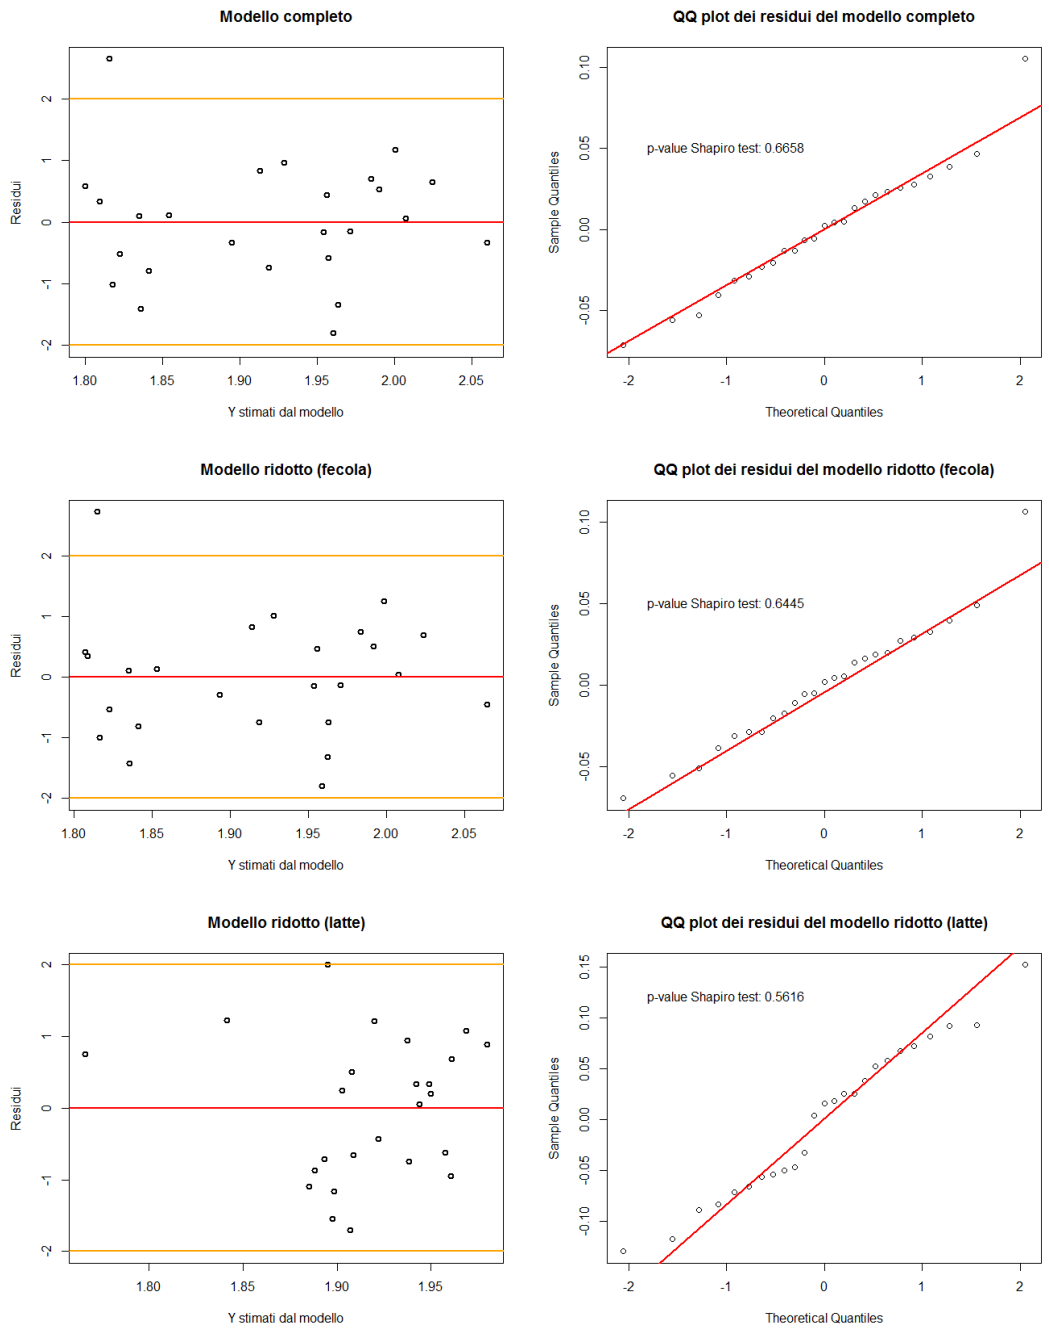

Figura 5: Grafici residui. Prima riga: grafici per il modello completo; seconda riga: grafici per il modello semplice con regressore fecola; terza riga: grafici per il modello semplice con regressore latte.

Soluzione 3. (a)

- modello completo: $D = \beta_0 + \beta_1 F + \beta_2 L + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \sigma^2),$
- modello ridotto 1: $D = \beta_0 + \beta_1 F + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \sigma^2),$
- modello ridotto 2: $D = \beta_0 + \beta_1 L + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \sigma^2).$

(b) Per rispondere alla domanda occorre fare un test F sui coefficienti dei regressori. In particolare per quanto riguarda il modello completo il test ha un p-value pari a $1.29 \cdot 10^{-8}$, di conseguenza il modello è significativo. Per quanto riguarda i modelli ridotti il test corrisponde al test sul singolo regressore, in particolare per il modello con solo il regressore fecola si ha un p-value di $1.07 \cdot 10^{-9}$ mentre per quello con solo latte si ha 0.007718. Entrambi i modelli ridotti risultano quindi significativi.

(c) Occorre guardare l'R^2. Per il modello completo abbiamo che l'R^2 è 0.8082, per il modello ridotto con solo il regressore fecola è 0.8075 mentre per il modello ridotto con solo regressore latte si ha un R^2 pari a 0.2704. Abbiamo quindo che il modello migliore in termini di R^2 è quello completo (non potrebbe essere altrimenti) che ha però un R^2 molto vicino a quello del modello ridotto con unico regressore la fecola. Se si guarda l'R^2 aggiustato abbiamo che il modello migliore risulta essere il modello ridotto con la fecola.

(d) Per verificare la normalità dei resuidui possiamo guardare il qq-plot e il p-value dello shapiro test. Per tutti e tre i modelli vediamo che i qq-plot non presentano anomalie e i p-value dello shapiro test sono tutti maggiori di 0.5 e non consentono quindi di rifiutare l'ipotesi di normalità. Quindi tutti e tre i modelli hanno residui normali.

Per verificare l'omoschedasticità guardiamo lo scatterplot dei residui contro i valori stimati. Abbiamo che per i primi due modelli i residui sono distribuiti omogeneamente intorno allo zero, e possiamo quindi concludere che i residui sono omoschedastici. Per il modello ridotto con regressore latte abbiamo che i residui sono spostati nella parte destra del grafico, e di conseguenza non sono omoschedastici.

(e) Occorre fare un t-test sul regressore latte. Possiamo ritenere attendibile il p-value del test dato che per il modello completo sono verificate le ipotesi di normalità e omoschedasticità dei residui.

Test: $H_0 : \beta_2 = 0$ vs $H_1 : \beta_2 \neq 0$

Statistica test: $\frac{\widehat{\beta_2}}{\mathrm{se}(\widehat{\beta_2})}$

p-value $= 0.7775$.

Non è possibile rifiutare l'ipotesi nulla, quindi il regressore latte non è significativo. Alla luce di quanto detto anche nei punti precedenti il modello migliore risulta il secondo (quello ridotto con regressore fecola).

(f)

$$H_0 : \beta_1 \leq 0.1, \qquad H_1 : \beta_1 > 0.1, \qquad RC : \widehat{\beta}_1 > 0.1 + \mathrm{se}(\widehat{\beta}_1)\, t_{1-\alpha}(23).$$

Calcolo p-value dei dati:

$$\widehat{\beta}_1 = 0.1 + \mathrm{se}(\widehat{\beta}_1)\, t_{1-\alpha}(23)$$

$$t_{1-\alpha}(23) = \frac{\widehat{\beta}_1 - 0.1}{\mathrm{se}(\widehat{\beta}_1)} = \frac{0.00384}{0.01057} = 0.363$$

Dalle tavole otteniamo che p-value > 0.25, per cui non posso rifiutare H_0 agli usuali livelli di significatività.