Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

II Appello di Statistica per Ingegneria Fisica — Prova scritta del 07/02/2025

Cognome

Nome

Matricola o Codice Persona	N.

Questo testo va consegnato insieme ai fogli con le soluzioni.

Su tutti i fogli che consegnerà, lo studente indichi il proprio cognome, nome e numero di matricola.
Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Tempo: 2h 30min

Problema 1. John Z. è un famoso micologo specializzato in funghi velenosi. Durante il periodo estivo John Z. ispeziona e controlla i cesti contenenti i funghi raccolti dai turisti. Ad ogni turista di cui controlla il cesto, John Z. indica i funghi velenosi. Sia X la variabile aleatoria che rappresenta il numero di funghi velenosi trovati nel cesto di un turista. X ha la seguente funzione di massa di probabilità:

$$p_X(x) := \begin{cases} \frac{1}{2}a^2 & \text{se } x = 0 \\ \frac{1}{4} & \text{se } x = 1 \\ \frac{1}{2}a & \text{se } x = 2 \\ \frac{1}{2}a & \text{se } x = 3 \\ \frac{1}{2}a^2 & \text{se } x = 4, \end{cases}$$

dove $a \in \mathbb{R}$ è un parametro.

(a) Per quali valori del parametro a la funzione p_X è una funzione di massa di probabilità?

D'ora in poi, fissate a in modo che p_X sia una funzione di massa di probabilità.

(b) Calcolate $\mathbb{E}[X]$ e $\mathrm{Var}(X)$, la moda e la mediana di X.

(c) Calcolate la probabilità che un turista abbia nel suo cesto almeno due funghi velenosi.

John Z. è molto scrupoloso e, ad ogni fungo velenoso trovato nel cesto di un turista, dedica esattamente 5 minuti di spiegazione sul come riconoscere (e quindi evitare di raccogliere) il suddetto fungo. Sia Y la variabile aleatoria che rappresenta il tempo che John Z. impiega a commentare il contenuto dell'intero cesto del turista.

(d) Determinate la funzione di ripartizione di Y e rappresentatela graficamente.

(e) Calcolate $\mathbb{E}[Y]$ e $\mathrm{Var}(Y)$.

Domani John Z. dovrà controllare i cesti di 45 turisti. John Z. è un appassionato montanaro e vuole finire di lavorare il prima possibile per poter andare a farsi un giro in montagna. Decide quindi che domani inizierà a lavorare alle ore 9:00 e non farà nessuna pausa finché non avrà ispezionato tutti i 45 cesti.

(e) Calcolate la probabilità (eventualmente approssimata) che John Z. riesca ad ispezionare tutti i cesti entro le ore 15:00.

Risultati.

(a) Affinché p_X sia una funzione di massa di probabilità si devono imporre le due condizioni:

$$\sum_{x=0}^{4} p_X(x) = 1 \qquad \text{e} \qquad p_X(x) \geq 0 \qquad \text{per} \qquad x \in \{0,1,2,3,4\}\,.$$

Imponendo la prima condizione si ottiene l'equazione di secondo grado

$$a^2 + a - \frac{3}{4} = 0$$

le cui due soluzioni sono $a_1 = -3/2$ e $a_2 = 1/2$. Imponendo la seconda condizione si ottiene $a \geq 0$, che porta a escludere la soluzione a_1. Si conclude che la funzione p_X è una funzione di massa di probabilità per $a = 1/2$.

(b) Col valore di a trovato al punto (a), abbiamo

$$p_X(0) = \frac{1}{8} \qquad p_X(1) = \frac{1}{4} \qquad p_X(2) = \frac{1}{4} \qquad p_X(3) = \frac{1}{4} \qquad p_X(4) = \frac{1}{8}$$

e dunque

$$\begin{aligned}
\mathbb{E}[X] &= \sum_{x=0}^{4} x\, p_X(x) = 0 \cdot \frac{1}{8} + 1 \cdot \frac{1}{4} + 2 \cdot \frac{1}{4} + 3 \cdot \frac{1}{4} + 4 \cdot \frac{1}{8} = 2\,,\\
\mathbb{E}\left[X^2\right] &= \sum_{x=0}^{4} x^2\, p_X(x) = 0^2 \cdot \frac{1}{8} + 1^2 \cdot \frac{1}{4} + 2^2 \cdot \frac{1}{4} + 3^2 \cdot \frac{1}{4} + 4^2 \cdot \frac{1}{8} = \frac{11}{2}\,,\\
\mathrm{Var}(X) &= \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2 = \frac{11}{2} - 2^2 = \frac{3}{2}\,,
\end{aligned}$$

$$\mathrm{Moda}(X) = \{1,2,3\},$$
$$\mathrm{Mediana}(X) = 2.$$

(c) $\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X = 0) - \mathbb{P}(X = 1) = 1 - p_X(0) - p_X(1) = 1 - 1/8 - 1/4 = 0.625.$

(d)

$$p_Y(y) = \begin{cases} \frac{1}{8} & \text{se } y = 0 \\ \frac{1}{4} & \text{se } y = 5 \\ \frac{1}{4} & \text{se } y = 10 \\ \frac{1}{4} & \text{se } y = 15 \\ \frac{1}{8} & \text{se } y = 20 \end{cases} \quad \Rightarrow \quad F_Y(y) = \begin{cases} 0 & \text{se } y < 0 \\ \frac{1}{8} & \text{se } 0 \leq y < 5 \\ \frac{3}{8} & \text{se } 5 \leq y < 10 \\ \frac{5}{8} & \text{se } 10 \leq y < 15 \\ \frac{7}{8} & \text{se } 15 \leq y < 20. \\ 1 & \text{se } \ y \geq 20. \end{cases}$$

(e) $Y = 5X$, pertanto utilizzando le proprietà di valore atteso e varianza,

$$\begin{aligned}
\mathbb{E}[Y] &= \mathbb{E}[5X] = 5\mathbb{E}[X] = 5 \cdot 2 = 10.0\,,\\
\mathrm{Var}(Y) &= \mathrm{Var}(5X) = 5^2 \mathrm{Var}(X) = 25 \cdot \frac{3}{2} = \frac{75}{2} = 37.5\,.
\end{aligned}$$

(f) Il tempo impiegato da John Z. per analizzare il contenuto dei 45 cesti è la variabile aleatoria

$$S_{45} = \sum_{i=1}^{45} Y_i\,,$$

dove Y_i è il tempo necessario per ispezionare il cesto dell'i-esimo turista, e le variabili $Y_1, \ldots, Y_{45}$ sono i.i.d. con la stessa media e la stessa varianza del punto precedente. Dalle 9:00 alle 15:00 trascorrono in tutto 360 minuti, dunque la probabilità richiesta è

$$\mathbb{P}(S_{45} \leq 360)\,.$$

Poiché il numero di cesti è alto ($45 > 30$), si può usare il TCL e approssimare la distribuzione di S_{45} nel modo seguente:

$$S_{45} \approx N\left(45 \cdot 10,\, 45 \cdot 37.5\right) = N\left(450,\, 1687.5\right).$$

Quindi

$$\begin{aligned}\mathbb{P}\left(S_{45} \leq 360\right) &\simeq \mathbb{P}\left(Z \leq \frac{360-450}{\sqrt{1687.5}}\right) = \mathbb{P}\left(Z \leq -2.190\right) = \Phi(-2.19) = 1 - \Phi(2.19) = 1 - 0.98574 \\ &= 0.01426\,,\end{aligned}$$

dove $Z = \left(S_{45} - \mathbb{E}\left[S_{45}\right]\right)/\sqrt{\mathrm{Var}\left(S_{45}\right)} \approx N(0,1)$.

Problema 2. L'azienda Opalea, che produce prodotti cosmetici, ha commissionato l'analisi del contenuto di parabeni (un tipo di conservante chimico) in diversi vasetti di crema. L'uso di parabeni nelle creme è regolato da limiti di legge per garantire la sicurezza dei consumatori, e si è stabilito che la concentrazione massima di parabeni ammessa in un prodotto cosmetico non deve superare $\mu_0 = 1.5$mg/Kg.
L'azienda ha commissionato l'analisi del contenuto di parabeni contenuto in un campione di 6 vasetti di crema di sua produzione. Il test di laboratorio ha una precisione nota e pari a ± 0.4mg/Kg. Possiamo dunque supporre che le 6 misure che ottiene costituiscano la realizzazione di un campione $X_1, \ldots, X_6$, centrato intorno alla concentrazione μ incognita di parabeni nella crema, e con deviazione standard $\sigma_0 = 0.4$mg/Kg nota. I dati raccolti sono i seguenti:

$$1.5 \qquad 1.33 \qquad 1.29 \qquad 1.25 \qquad 1.31 \qquad 1.52.$$

(a) Per un'analisi statistica dei sei dati chiarire che ipotesi sia sensato fare sulla densità del campione $(X_1, \ldots X_6)$, i.e. detta X la concentrazione di parabeni in un vasetto di crema, indicare la distribuzione di X specificandone media e varianza. Motivare adeguatamente la risposta.

(b) Considerare i seguenti due stimatori per μ:

$$\Theta = \frac{X_1}{4} + \frac{X_2}{12} + \frac{1}{6}\sum_{i=3}^{6} X_i,$$

$$\Psi = \frac{1}{5}\left(\sum_{i=1}^{5} X_i + 2X_6\right).$$

Studiare la distorsione di Θ e Ψ e calcolarne l'errore quadratico medio. Quale dei due stimatori é migliore? Motivare la risposta.

(c) Proporre uno stimatore per μ che risulti migliore di quelli considerati nel punto precedente. Motivare adeguatamente la risposta.

D'ora in avanti procedere sotto le assunzioni del punto (a).

(d) Al livello di confidenza del 90%, fornire un limite superiore (cioè del tipo $\mu < c$) per la concentrazione media di parabeni.

(e) Prima di mettere la crema in commercio, l'azienda Opalea vuole stabilire con un elevato grado di sicurezza che essa non sia dannosa per la salute delle persone.

- Scrivere le ipotesi statistiche di un test adatto a questo scopo.
- Scrivere inoltre la regione di rifiuto per tale test al livello di significatività α.

(f) Coi dati a disposizione, che conclusione dà il test precedente al livello $\alpha = 5\%$?

(g) Determinare dai dati il p-value del test del punto (f). In base a questo valore, vi sentireste sicuri ad usare la crema dell'azienda Opalea?

(h) Supponiamo che la vera concentrazione di parabeni sia $\mu = 1.2$mg/Kg; la crema, quindi, non è dannosa. In questo caso, però, qual è la probabilità che il test del punto (c) con $\alpha = 5\%$ ci faccia erroneamente concludere che la crema sia tossica?

Risultati.

(a) Dato che il campione è poco numeroso ($n = 6$) dobbiamo assumere che le X_i, $i = 1 \dots 6$ abbiano distribuzione gaussiana. In particolare, $X \sim \mathcal{N}(\mu, \sigma_0^2)$.

(b) Tenendo a mente quanto affermato nel punto (a), dalla linearità del valore atteso segue che

$$\mathbb{E}[\Theta] = \frac{\mathbb{E}[X_1]}{4} + \frac{\mathbb{E}[X_2]}{12} + \frac{1}{6}\sum_{i=3}^{6}\mathbb{E}[X_i] = \mu.$$

Lo stimatore è dunque non distorto. Di conseguenza $\text{Bias}[\Theta] = 0$ e il suo errore quadratico medio coincide con la sua varianza

$$\text{MSE}(\Theta, \mu) = \mathbb{V}ar(\Theta) = \frac{1}{16}\mathbb{V}ar(X_1) + \frac{1}{144}\mathbb{V}ar(X_2) + \frac{1}{36}\sum_{i=3}^{6}\mathbb{V}ar(X_i) = \frac{13}{72}\sigma_0^2.$$

Per lo stimatore Ψ invece abbiamo

$$\mathbb{E}[\Psi] = \frac{1}{5}\left(\sum_{i=1}^{5}\mathbb{E}[\Psi] + 2\mathbb{E}[\Psi]\right) = \frac{7}{5}\mu \neq \mu.$$

Lo stimatore é quindi distorto e si ha

$$\text{Bias}(\Psi, \mu) := \mathbb{E}[\Psi] - \mu = \frac{7}{5}\mu - \mu = \frac{2}{5}\mu.$$

L'errore quadratico medio é

$$\text{MSE}(\Psi, \mu) := \mathbb{V}ar(\Psi) + \text{Bias}(\Psi, \mu)^2,$$

dove

$$\mathbb{V}ar(\Psi) = \frac{1}{25}\left(\sum_{i=1}^{5}\mathbb{V}ar(X_i) + 4\mathbb{V}ar(X_6)\right) = \frac{1}{25}(5\sigma_0^2 + 4\sigma_0^2) = \frac{9}{25}\sigma_0^2.$$

Concludiamo che

$$\text{MSE}(\Psi, \mu) = \frac{1}{25}\left(9\sigma_0^2 + 4\mu^2\right).$$

Tra i due stimatori il migliore é Θ. Innanzitutto é non distorto, inoltre

$$\text{MSE}(\Theta, \mu) = \frac{13}{72}\sigma_0^2 < \text{MSE}(\Psi, \mu) = \frac{1}{25}\left(9\sigma_0^2 + 4\mu^2\right).$$

(c) La media campionaria $\bar{X} = \frac{1}{6}\sum_{i=1}^{6} X_i$ è uno stimatore non distorto di μ. Il suo errore quadratico medio è pari a

$$\mathbb{V}ar(\bar{X}) = \frac{\sigma_0^2}{36}.$$

La media campionaria risulta essere uno stimatore migliore di quelli proposti nel punto (b) perchÃ¨ non distorto e tale che

$$\frac{\sigma_0^2}{36} = \text{MSE}(\bar{X}, \mu) < \text{MSE}(\Theta, \mu) < \text{MSE}(\Psi, \mu).$$

(d) $IC_\mu(\gamma = 90\%)$ unilatero destro a varianza nota:

$$\mu \in \left(-\infty\,,\, \bar{x}_n + z_\gamma \frac{\sigma_0}{\sqrt{n}}\right) = \left(-\infty\,,\, 1.3667 + 1.28\,\frac{0.4}{\sqrt{6}}\right) = (-\infty\,,\, 1.5757).$$

(e) Test per le ipotesi

$$H_0 : \mu \geq 1.5 = \mu_0 \qquad \text{contro} \qquad H_1 : \mu < \mu_0\,.$$

Regola del test al livello di significatività α:

$$\text{rifiuto } H_0 \text{ se} \quad \frac{\bar{x}_n - \mu_0}{\sigma_0}\sqrt{n} = \frac{\bar{x}_6 - 1.5}{0.4}\sqrt{6} < -z_{1-\alpha}\,.$$

(f) Con $\alpha = 5\%$ e i dati assegnati

$$\frac{\bar{x}_6 - 1.5}{0.4}\sqrt{6} = \frac{1.3667 - 1.5}{0.4}\sqrt{6} = -0.8165 \not< -z_{1-\alpha} = -1.645 \quad \Rightarrow \quad \text{accetto } H_0\,.$$

In altre parole, al 5% di significatività *non* c'è evidenza che la crema sia sicura.

(g) $-z_{1-p\text{-value}} = (\bar{x}_n - \mu_0)\sqrt{n}/\sigma_0 = -0.8165 \quad \Rightarrow \quad p\text{-value} = 1 - \Phi(0.8165) = 20.71\%$.
Con un p-value così elevato, H_0 non può essere rifiutata. Di conseguenza, *non* mi sentirei affatto sicuro di usare la crema dell'azienda Opalea.

(h) Si tratta di calcolare la probabilità di errore di II specie

$$\begin{aligned}
\mathbb{P}_{\mu=1.2}(\text{“accetto } H_0\text{”}) &= \mathbb{P}_{\mu=1.2}\left(\frac{\bar{X}_n - \mu_0}{\sigma_0}\sqrt{n} \geq -z_{1-0.05}\right) \\
&= \mathbb{P}_{\mu=1.2}\left(\underbrace{\frac{\bar{X}_n - \mu}{\sigma_0}\sqrt{n}}_{N(0,1)} \geq -z_{0.95} + \frac{\mu_0 - \mu}{\sigma_0}\sqrt{n}\right) \\
&= 1 - \Phi\left(-z_{0.95} + \frac{\mu_0 - 1.2}{\sigma_0}\sqrt{n}\right) = 1 - \Phi\left(-1.645 + \frac{1.5 - 1.2}{0.4}\sqrt{6}\right) \\
&= 1 - \Phi(0.19212) = 42.38\%\,.
\end{aligned}$$

Problema 3.

La divisione di ricerca e sviluppo di un'azienda multinazionale che opera nel settore della tecnologia dei giroscopi sta sperimentando un nuovo modello di giroscopio per applicazioni di navigazione. Vengono quindi testati 296 prototipi di giroscopi, ognuno installato su veicoli in regioni con caratteristiche ambientali differenti. Vengono raccolti i dati relativi alla precisione di rilevamento (G) per ogni giroscopio (in millimetri), alla temperatura media (T) nell'ambiente di test (in gradi Celsius) e all'umidità relativa dell'aria (U) durante i test (in percentuale). Si vuole anche valutare come la precisione di rilevamento dipenda dalla temperatura e dall'umidità medie registrate. Le medie campionarie e le varianze campionarie dei dati raccolti sono:

$$\overline{g} = 182.1922,\ s_g^2 = 1390.459, \qquad \overline{t} = 17.61963,\ s_t^2 = 14.1843, \qquad \overline{u} = 62.88284,\ s_u^2 = 88.23529.$$

Nelle figure 1 e 2 vengono proposti gli output di R del modello di regressione, il grafico dei residui e i p-value del test di Shapiro-Wilk per i residui per ciascuno dei seguenti modelli:

$$\text{Modello 1: } G_i = \beta_0 + \beta_1 T_i + \beta_2 U_i + \epsilon_i$$

$$\text{Modello 2: } G_i = \beta_0 + \beta_1 T_i + \epsilon_i$$

con $\epsilon_i \sim N(0, \sigma^2)$, per $i = 1, ..., 296$.

(a) Si commenti la bontà dei modelli proposti, in particolare

- i due modelli sono globalmente significativi?
- Quali dei due modelli spiegano meglio la variabilità della risposta?
- Quali dei due modelli hanno residui normali? Quali dei due modelli hanno residui omoschedastici?

Si scelga di conseguenza il migliore per descrivere il problema in esame.

(b) Si scriva l'equazione di regressione stimata per il modello prescelto.

(c) Fornire una previsione intervallare al 90% della precisione di rilevamento (G) che verrebbe ottenuta in un nuovo test, dove si prevede che la temperatura media sia 22 gradi e l'umidità relativa sia dell'85%.

Per una diversa serie di giroscopi, già in uso, si ha la seguente stima per il coefficiente relativo alla temperatura: $\hat{\beta}_1^* = 10$.

(d) È possibile affermare che il coefficiente di dipendenza lineare dalla temperatura sia diverso nelle due serie di giroscopi? Effettuare un opportuno test al 5%.

```
Call:
lm(formula = G ~ T + U)

Residuals:
    Min      1Q  Median      3Q     Max
-28.161  -6.762  -0.285   6.986  31.820

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 10.14154    6.05040   1.676   0.0948 .
T            9.58378    0.16809  57.017   <2e-16 ***
U            0.05070    0.06739   0.752   0.4525
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.06 on 293 degrees of freedom
Multiple R-squared: 0.9277,     Adjusted R-squared: 0.9272
F-statistic:  1881 on 2 and 293 DF,  p-value: < 2.2e-16

> res1 <- mod1$residuals
> shapiro.test(res1)

        Shapiro-Wilk normality test

data:  res1
W = 0.9973, p-value = 0.9054
```

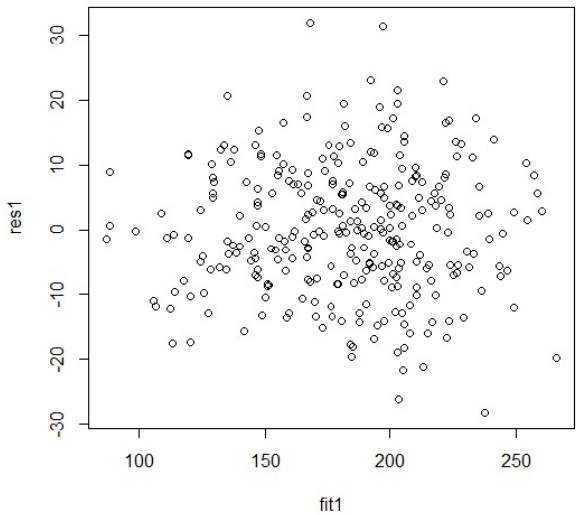

Figura 1: Output dell'analisi per il Modello 1

```
Call:
lm(formula = G ~ T)

Residuals:
    Min      1Q  Median      3Q     Max
-27.481  -6.295  -0.308   6.959  31.983

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  14.1758     2.7993   5.064 7.25e-07 ***
T             9.5358     0.1554  61.373  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 10.05 on 294 degrees of freedom
Multiple R-squared: 0.9276,     Adjusted R-squared: 0.9274
F-statistic:  3767 on 1 and 294 DF,  p-value: < 2.2e-16

> res2 <- mod2$residuals
> shapiro.test(res2)

        Shapiro-Wilk normality test

data:  res2
W = 0.9971, p-value = 0.8808
```

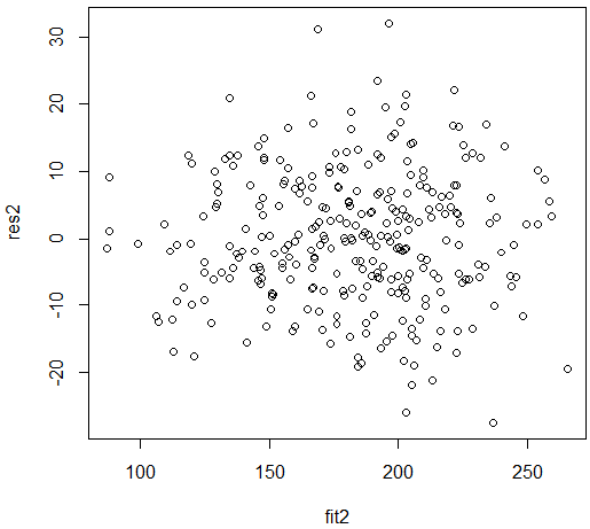

Figura 2: Output dell'analisi per il Modello 2

Risultati.

(a) Il Modello 1 ha un R^2-adjusted molto elevato, i residui non presentano particolari trend. Considerando il p-value del test di Shapiro-Wilks, l'ipotesi della normalità dei residui non è rifiutata a tutti i livelli usuali. Pertanto è possibile considerare i test di significatività proposti nell'output di R. Il modello è globalmente significativo (p-value: $< 2.2e-16$), ma il coefficiente β_2 risulta non significativamente diverso da 0 (p-value: 0.4525). Per questo motivo sarebbe opportuno eliminare il predittore U dal modello.

Il Modello 2, ottenuto proprio eliminando U, presenta le stesse buone caratteristiche del Modello 1, ma in questo caso tutti i predittori risultano significativi. Inoltre R^2-adjusted è leggermente aumentato. È un modello più semplice del Modello 1, avendo un regressore in meno, ma ha le stesse performances, se non leggermente superiori. Per questi motivi è opportuno scegliere il Modello 2.

(b) L'equazione stimata per il modello 2 è la seguente:

$$\hat{G} = 14.1758 + 9.5358 \times T.$$

(c) La previsione puntuale per la precisione di rilevamento è $\hat{G}_0 = \hat{G}_{|T=t_0=22} = 14.1758 + 9.5358 \times 22 = 223.9634$. L'intervallo di previsione cercato è: $\hat{G}_0 \pm t_{0.950}(n-2)\hat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(t_0-\bar{t})^2}{S_{tt}}}$, con $S_{tt} = s_t^2(n-1)$, $t_{0.950}(n-2) \simeq z_{0.950} = 1.645$ e $\hat{\sigma} = 10.05$, da cui ricaviamo l'intervallo: $[207.365, 240.561]$.

(d) Il test di ipotesi è il seguente: $H_0 : \beta_1 = 10$ vs. $H_1 : \beta_1 \neq 10$. Quindi, eseguendo un t-test al 5% sul coefficiente β_1 si ottiene: $|t_0| = |\hat{\beta}_1 - 10|/\text{se}(\hat{\beta}_1) = 2.987129 > t_{0.975}(n-2) \simeq z_{0.975} = 1.960$, quindi al 5% c'è evidenza per rifiutare H_0.