Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

III Appello di Statistica per Ingegneria Fisica — Prova scritta del 14/06/2025

Cognome	
Nome	
Matricola o Codice Persona	N.

Questo testo va consegnato insieme ai fogli con le soluzioni.

Su tutti i fogli che consegnerà, lo studente indichi il proprio cognome, nome e numero di matricola.
Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Tempo: 2h 30min

Problema 1.

Nel laboratorio di chimica avanzata del professor Tungsteno, gli studenti stanno conducendo esperimenti con reattivi instabili che si decompongono spontaneamente dopo un certo tempo aleatorio, rendendo impossibile continuare l'esperimento. Ogni reattivo rimane attivo per un tempo casuale che segue una distribuzione esponenziale con valore atteso pari a 1 ora. I tempi di decomposizione di reattivi diversi sono indipendenti.

Oggi lo studente Marco lavorerà con due reattivi, A e B, che devono rimanere entrambi stabili per l'intera durata dell'esperimento. L'esperimento termina non appena uno dei due reattivi si disattiva.

(a) Per ogni $t > 0$, calcolare:

  (i) la probabilità che il reattivo A sia ancora attivo dopo t ore;

  (ii) la probabilità che entrambi i reattivi A e B siano ancora attivi dopo t ore.

(b) Sia T il tempo che passa dall'inizio dell'esperimento fino a quando almeno uno dei due reattivi diventa inattivo. Determinare la funzione di ripartizione F_T della variabile aleatoria T.

(c) Ricavare la densità di T e calcolare il suo valore atteso.

(d) Il professor Tungsteno desidera che l'esperimento di Marco abbia una probabilità di successo di almeno il 60% (cioè una probabilità al massimo del 40% che almeno un reattivo si disattivi prima del termine). Quanto può essere la durata massima t_0 dell'esperimento?

(e) Oggi in laboratorio ci sono 55 studenti, e ognuno di loro condurrà un esperimento, della durata fissata a t_0 ore (dove t_0 è stato calcolato al punto precedente), con la coppia dei reattivi A e B. Qual è la probabilità approssimata che almeno 20 studenti vedano il proprio esperimento interrotto prima del termine a causa della disattivazione di almeno uno dei due reattivi?

Risultati.

(a) (i) Sia T_A l'istante in cui il reattivo A si disattiva (ovvero il tempo fino al quale il reattivo A rimane stabile). Sappiamo che $T_A \sim \mathcal{E}(1/1) = \mathcal{E}(1)$, e quindi la probabilità richiesta è

$$\mathbb{P}(T_A > t) = \int_t^{+\infty} f_{T_A}(z)\mathrm{d}z = \int_t^{+\infty} \mathrm{e}^{-z}\mathrm{d}z = \mathrm{e}^{-t}\,.$$

Alternativamente, ricordando che la funzione di ripartizione di una variabile aleatoria esponenziale di parametro 1 è della forma $F_T(t) = (1 - e^{-t})\mathbf{1}_{(0,+\infty)}$, abbiamo

$$\mathbb{P}(T_A > t) = 1 - F_T(t) = e^{-t}.$$

(ii) Sia T_B l'istante in cui il reattivo B si disattiva. Sappiamo che anche $T_B \sim \mathcal{E}(1/1) = \mathcal{E}(1)$ e che T_A e T_B sono indipendenti. Quindi, la probabilità richiesta è

$$\mathbb{P}(T_A > t, T_B > t) = \mathbb{P}(T_A \geq t) \cdot \mathbb{P}(T_B \geq t) = \mathrm{e}^{-t} \cdot \mathrm{e}^{-t} = \mathrm{e}^{-2t}\,.$$

Alternativamente, sia X_t il numero di reattivi ancora stabili al tempo t. Allora, $X_t \sim B(2, p)$, dove $p = \mathrm{e}^{-t}$ è la probabilità trovata al punto (i). La probabilità richiesta si può dunque calcolare anche come

$$\mathbb{P}(X_t = 2) = \binom{2}{2} p^2(1-p)^{2-2} = p^2 = \mathrm{e}^{-2t}\,.$$

(b) Sia T l'istante in cui almeno uno dei due reattivi diventa inattivo, vale a dire l'istante in cui si interrompe l'esperimento. Dato che l'esperimento prosegue finantochè entrambi i reattivi sono attivi, abbiamo l'uguaglianza di eventi

$$\{T > t\} = \{T_A > t\} \cap \{T_B > t\}$$

e dunque per $t > 0$ la funzione di ripartizione è

$$F_T(t) = \mathbb{P}(T \leq t) = 1 - \mathbb{P}(T > t) = \mathbb{P}(T_A > t, T_B > t) = 1 - \mathrm{e}^{-2t}\,.$$

Alternativamente, si può usare l'uguaglianza di eventi

$$\{T \leq t\} = \{X_t \leq 1\}\,,$$

dove X_t è il numero di reattivi ancora stabili al tempo t introdotto al punto precedente. Di conseguenza,

$$F_T(t) = \mathbb{P}(T \leq t) = \mathbb{P}(X_t \leq 1) = 1 - \mathbb{P}(X_t = 2) = 1 - p^2 = 1 - \mathrm{e}^{-2t}\,,$$

che è lo stesso risultato. Ovviamente, per $t \leq 0$ abbiamo

$$F_T(t) = \mathbb{P}(T \leq t) = \mathbb{P}(\emptyset) = 0\,.$$

(c) Per ricavare la densità di T, deriviamo la sua funzione di ripartizione:

$$f_T(t) = \frac{\mathrm{d}}{\mathrm{d}t} F_T(t) = \begin{cases} \frac{\mathrm{d}}{\mathrm{d}t}(1 - \mathrm{e}^{-2t}) = 2\mathrm{e}^{-2t} & \text{se } t > 0 \\ \frac{\mathrm{d}}{\mathrm{d}t} 0 = 0 & \text{se } t \leq 0 \end{cases}$$

Nella funzione $f_T(t) = 2\mathrm{e}^{-2t}\mathbf{1}_{(0,+\infty)}(t)$, riconosciamo la densità esponenziale di parametro 2, cioè $T \sim \mathcal{E}(2)$. Dal formulario, troviamo che il suo valore atteso è $\mathbb{E}[T] = 1/2$.

(d) Il prof. Tungsteno vuole trovare t_0 tale che $\mathbb{P}(T > t_0) = 0.6 \iff F_T(t_0) = \mathbb{P}(T \leq t_0) = 0.4$. Per farlo, deve risolvere l'equazione

$$F_T(t_0) = 0.4 \quad \Rightarrow \quad 1 - \mathrm{e}^{-2t} = 0.4 \quad \Rightarrow \quad t = -\frac{1}{2}\ln(1 - 0.4) \approx 0.255.$$

(e) Sia Y il numero di studenti che non portano a termine l'esperimento nel tempo t_0 a disposizione. Allora $Y \sim B(55, 0.4)$, dove 0.4 è la probabilità del punto precedente. Vogliamo calcolare

$$\mathbb{P}(Y \geq 20) = \mathbb{P}(Y \geq 19.5) = \mathbb{P}\left(\underbrace{\frac{Y - np}{\sqrt{np(1-p)}}}_{\approx N(0,1)} \geq \frac{19.5 - 55 \cdot 0.4}{\sqrt{55 \cdot 0.4 \cdot (1 - 0.4)}} \right)$$

$$\simeq 1 - \Phi\left(\frac{19.5 - 55 \cdot 0.4}{\sqrt{55 \cdot 0.4 \cdot (1 - 0.4)}} \right) = 1 - \Phi(-0.6881) = \Phi(0.6881) \approx 0.7549.$$

Abbiamo potuto usare l'approssimazione gaussiana della binomiale perché $n > 20$, $np = 22 > 5$ e $n(1-p) = 33 > 5$.

Problema 2.

Matilde è una mastra birraia rinomata per l'attenzione al dettaglio nella produzione artigianale delle sue birre. In particolare, ha appena introdotto un nuovo sistema per il controllo della fermentazione delle sue birre. La fermentazione è un processo che può richiedere diversi giorni per essere completato, a seconda della temperatura, della quantità di lievito e di altri fattori ambientali.
Secondo le specifiche, ogni lotto di birra dovrebbe richiedere una fermentazione di $\mu = 60$ giorni in media, ma Matilde sa che, a causa della variabilità dei fattori ambientali, il tempo di fermentazione T (in giorni) può variare da lotto a lotto. Grazie alla qualità dell'impianto, Matilde ha progettato il sistema in modo da mantenere la deviazione standard del tempo di fermentazione a circa $\sigma = 0.5$ giorni.
Per verificare che il sistema stia funzionando correttamente, Matilde decide di raccogliere un campione di n lotti di birra, misurando il tempo effettivo di fermentazione per ciascun lotto. Questi sono tra loro indipendenti.

(a) Supponiamo di voler utilizzare il campione $(t_1, \ldots, t_n)$ dei tempi misurati da Matilde per stimare μ. Qual è il numero minimo di misurazioni n^* necessario a garantire una stima intervallare al 90% con semi-ampiezza inferiore a 0.1 giorni? Che ipotesi bisogna fare sul campione per poter rispondere ad una tale domanda?

Alla fine Matilde raccoglie un campione di $n = 70$ lotti di birra, misurando il tempo effettivo di fermentazione per ciascun lotto. Analizzando i dati ottenuti con R, Matilde ottiene i seguenti dati (misurati in giorni):

$$\bar{t}_n = 59.9847, \qquad s_n^2 = 0.2134407.$$

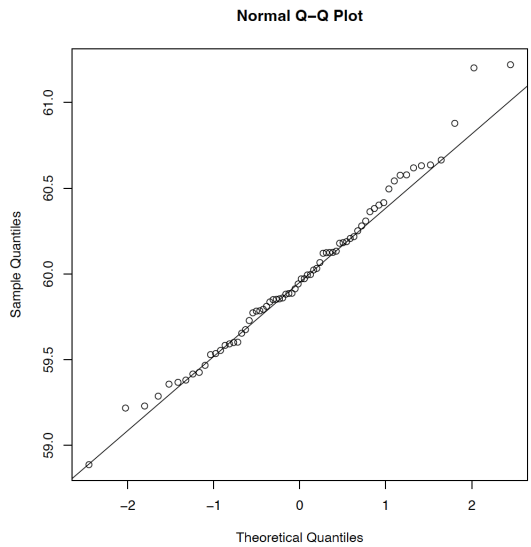


```
        Shapiro-Wilk normality test

data:  T
W = 0.98651, p-value = 0.6572
```

Matilde ha già completato la produzione: la birra è stata imbottigliata e stoccata per la vendita. Intervenire ora sul processo di fermentazione comporterebbe costi elevati e ritardi significativi. Per questo motivo, Matilde è disposta a modificare il processo solo se i dati raccolti forniscono una forte evidenza statistica che il tempo medio di fermentazione μ sia diverso da 60 giorni.

(b) Si imposti un opportuno test d'ipotesi per stabilire se il processo di fermentazione debba essere modificato. *[Specificare ipotesi del test e regione critica di livello α.]*

(c) Si calcoli il p-value. Cosa consigliereste a Matilde?

(d) Calcolare la potenza del test, nel caso di un livello di significatività del 10% e nell'ipotesi che il tempo medio μ sia in realtà 58 giorni.

(d) Le procedure ai punti (a), (b) e (c) sono giustificate? Perché?

Risultati.

(a) Dato un campione i.i.d. di ampiezza n, ipotizzando la popolazione normale o il campione numeroso, la semi-ampiezza dell'intervallo di confidenza al 90% per μ è

$$z_{0.95}\frac{\sigma}{\sqrt{n}},$$

dove $\sigma = 0.5$ è la deviazione standard garantita da Matilde. Pertanto,

$$z_{0.95}\frac{\sigma}{\sqrt{n}} < 0.1 \quad \Longrightarrow \quad n \geq \left(\frac{z_{0.95}\sigma}{0.1}\right)^2 = 67.63859,$$

da cui $n^* = 68$.

(b) Introduciamo il test

$$H_0 : \mu = 60 \quad \text{vs} \quad H_1 : \mu \neq 60,$$

la cui regione critica di livello α, nel caso di popolazione normale o campione numeroso, è:

$$RC_\alpha = \left\{ \left|\bar{T}_n - 60\right| > z_{1-\frac{\alpha}{2}}\frac{\sigma}{\sqrt{n}} \right\}.$$

(c) Il p-value dei dati, α^*, soddisfa:

$$|\bar{t}_n - 60| = z_{1-\frac{\alpha^*}{2}}\frac{\sigma}{\sqrt{n}} \quad \Longrightarrow \quad z_{1-\alpha^*/2} = \frac{\sqrt{n}|\bar{t}_n - 60|}{\sigma},$$

da cui si ottiene $z_{1-\alpha^*/2} \approx 0.256015$, da cui $\alpha^* \approx 2(1 - \Phi(0.256015)) \approx 0.8$. Visto il p-value piuttosto elevato, non c'è motivo perché Matilde debba modificare il processo di fermentazione.

(d) La potenza del test per $\mu = 58$ è:

$$\begin{aligned}
\mathbb{P}\left(\bar{T}_n \in RC_{0.1} \mid \mu = 58\right) &= \mathbb{P}\left(\bar{T}_n > 60 + z_{0.95}\frac{\sigma}{\sqrt{n}} \mid \mu = 58\right) + \mathbb{P}\left(\bar{T}_n < 60 - z_{0.95}\frac{\sigma}{\sqrt{n}} \mid \mu = 58\right) \\
&= \mathbb{P}\left(\frac{\bar{T}_n - \mu}{\frac{\sigma}{\sqrt{n}}} > \frac{60-\mu}{\frac{\sigma}{\sqrt{n}}} + z_{0.95} \mid \mu = 58\right) + \mathbb{P}\left(\frac{\bar{T}_n - \mu}{\frac{\sigma}{\sqrt{n}}} < \frac{60-\mu}{\frac{\sigma}{\sqrt{n}}} - z_{0.95} \mid \mu = 58\right) \\
&= \mathbb{P}\left(Z > z_{0.95} + \frac{2}{\sqrt{\sigma^2/n}}\right) + \mathbb{P}\left(Z < -z_{0.95} + \frac{2}{\sqrt{\sigma^2/n}}\right) \approx 1,
\end{aligned}$$

dove $Z := \frac{\bar{T}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$.

(e) Sì. Al punto (a) abbiamo $n^* = 68 \geq 30$, pertanto, le stime intervallari su cui si basano i conti hanno un livello di confidenza che è approssimativamente quello nominale (campione numeroso, teorema centrale del limite). Ai punti (b), (c) e (d) vale un discorso analogo, essendo $n = 70 \geq 30$, senza contare che il test di Shapiro-Wilk ci confermerebbe anche la normalità della popolazione.

Problema 3. La TechNova S.r.l. è un'azienda specializzata nello sviluppo di infrastrutture server per data center ad alta efficienza. In questi giorni sta testando un nuovo tipo di modulo di calcolo dotato di un sistema di controllo termico intelligente. È fondamentale tenere monitorata la temperatura interna del modulo, per garantirne l'affidabilità e prevenire surriscaldamenti.

L'azienda è interessata a studiare la relazione tra la temperatura interna Y del modulo, la temperatura ambientale T, nella sala server, il numero medio di richieste simultanee N gestite dal modulo. Vengono raccolti i dati relativi a 20 moduli di calcolo, ottenendo i seguenti valori di sintesi (medie e varianze campionarie):

$$\bar{y} = 57.1628,\ s_y^2 = 64.0205; \qquad \bar{t} = 29.1386,\ s_t^2 = 20.0575; \qquad \bar{n} = 6.3,\ s_n^2 = 12.6421.$$

In Figura 1 e Figura 2 vengono proposti gli output di R del modello di regressione, il grafico dei residui e i p-value del test di Shapiro-Wilk per i residui per ciascuno dei seguenti modelli:

$$\text{Modello 1:} \qquad Y = \beta_0 + \beta_1 T + \beta_2 N + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

$$\text{Modello 2:} \qquad Y = \beta_0 + \beta_1 T + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

(a) Si commenti la bontà dei modelli proposti, in particolare,

- i due modelli sono globalmente significativi?
- Quali dei due modelli spiegano meglio la variabilità della risposta?
- Quali dei due modelli hanno residui normali? Quali dei due modelli hanno residui omoschedastici?

Si scelga di conseguenza il miglior modello per descrivere il problema in esame.

(b) Si scriva l'equazione di regressione stimata per il modello prescelto.

(c) Un modulo dello stesso tipo viene integrato in un dispositivo per il monitoraggio climatico all'aperto. Oggi, la temperatura ambiente nella zona d'installazione è di 33°C, e il modulo dovrà gestire 10 richieste simultanee. Calcolare la stima puntuale della temperatura interna del modulo, utilizzando il modello scelto.

(d) Calcolare un intervallo di previsione al 95% per la temperatura interna del modulo, alle condizioni del punto (c).

Per una diversa serie di moduli di calcolo, già in uso, si ha la seguente stima per il coefficiente relativo alla temperatura: $\hat{\beta}_1^* = 2$.

(e) E' possibile affermare che il coefficiente di dipendenza lineare della temperatura sia diverso nelle due serie di moduli di calcolo? Effettuare un opportuno test al 1%.

```
Call:
lm(formula = Y ~ T + N)

Residuals:
     Min       1Q   Median       3Q      Max
-2.68410 -1.06505 -0.01521  0.98577  2.15461

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  4.57371    2.36586   1.933    0.070 .
T            1.77796    0.07404  24.012 1.48e-14 ***
N            0.12409    0.09326   1.331    0.201
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.417 on 17 degrees of freedom
Multiple R-squared: 0.9719, Adjusted R-squared: 0.9686
F-statistic: 294.2 on 2 and 17 DF,  p-value: 6.476e-14

> shapiro.test(regr1$residuals)

 Shapiro-Wilk normality test

data:  regr1$residuals
W = 0.9777, p-value = 0.9017
```

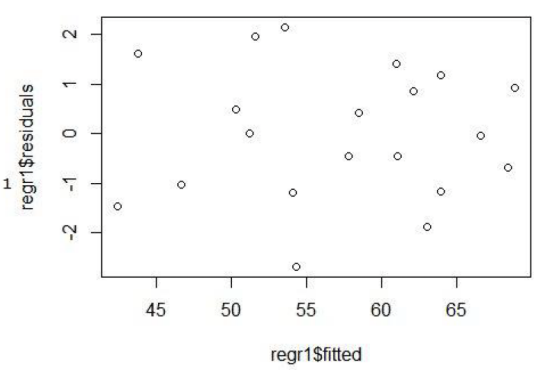

Figura 1: Output dell'analisi per il modello 1

```
Call:
lm(formula = Y ~ T)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.3658 -0.6532  0.2742  0.9621  1.8334 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept)  5.91778    2.18463   2.709   0.0144 *  
T            1.75866    0.07415  23.719 4.98e-15 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.447 on 18 degrees of freedom
Multiple R-squared: 0.969, Adjusted R-squared: 0.9673 
F-statistic: 562.6 on 1 and 18 DF,  p-value: 4.979e-15

> shapiro.test(regr2$residuals)

 Shapiro-Wilk normality test

data:  regr2$residuals
W = 0.9375, p-value = 0.2148
```

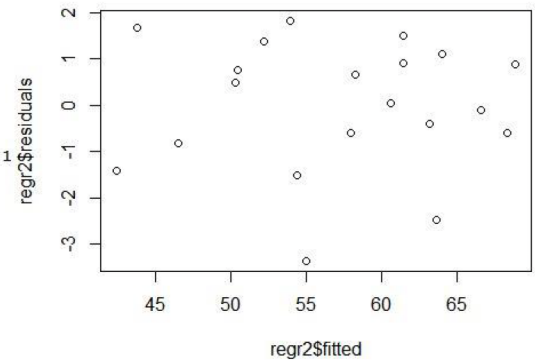

Figura 2: Output dell'analisi per il modello 2

Risultati.

(a) Il Modello 1 ha un R^2 adjusted molto elevato, I residui non presentano particolari trend. Considerando il p-value del test di Shapiro-Wilks, l'ipotesi della normalità dei residui non è rifiutata a tutti i livelli usuali. Pertanto è possibile considerare i test di significatività proposti nell'output di R. Il modello è globalmente significativo (p-value: 6.476×10^{-14}), ma il coefficiente β_2 risulta non significativamente diverso da 0 (p-value: 0.201), e anche l'intercetta del modello potrebbe non essere significativamente diversa da zero (p-value: 0.070). Sarebbe opportuno eliminare il predittore N dal modello.

Il Modello 2, ottenuto proprio eliminando N, presenta le stesse buone caratteristiche del Modello 1, ma in questo caso tutti i predittori risultano significativi. È un modello più semplice del Modello 1, avendo un regressore in meno, ma ha le stesse performance. Per questi motivi è opportuno scegliere il Modello 2.

(b) L'equazione stimata per il Modello 2 è la seguente:

$$\hat{Y} = 5.91778 + 1.75866\,T$$

(c) La previsione puntuale per la temperatura del processore è:

$$\hat{Y}_0 = \hat{Y}_{|T=t_0=33} = 5.91778 + 1.75866 \times 33 = 63.95356.$$

(d) L'intervallo di previsione cercato è:

$$\left(\hat{Y}_0 - t_{0.975}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(t_0-\bar{t})^2}{S_{tt}}}, \hat{Y}_0 + t_{0.975}(n-2)\hat{\sigma}\sqrt{1+\frac{1}{n}+\frac{(t_0-\bar{t})^2}{S_{tt}}}\right),$$

dove $n = 20$, $\hat{\sigma} = 1.447$, $t_{0.975}(n-2) = t_{0.975}(18) = 2.1009$, $S_{tt} = (n-1)\left(\frac{1}{n-1}\sum_{i=1}^{n}(t_i-\bar{t})^2\right) = s_t^2(n-1)$. Con i dati a disposizione si ottiene:

$$[60.78094, 67.12618].$$

(e) Il test d'ipotesi da considerare è il seguente: $H_0 : \beta_1 = 2$ vs $H_0 : \beta_1 \neq 2$. Eseguiamo un t-test al 1% sul coefficiente β_1. Con i dati $se(\hat{\beta}_1) = 0.07415, \hat{\beta}_1 = 1.75866$, otteniamo

$$t_0 = |\hat{\beta}_1 - 2|/se(\hat{\beta}_1) \approx 3.255 > t_{1-\frac{\alpha}{2}}(n-2) = t_{0.995}(18) = 2.8784.$$

Quindi al 1% c'è evidenza per rifiutare H_0.