Politecnico di Milano - Scuola di Ingegneria Industriale e dell'Informazione

IV Appello di Statistica per Ingegneria Fisica — Prova scritta del 09/07/2025

Cognome	
Nome	
Matricola o Codice Persona	N.

Questo testo va consegnato insieme ai fogli con le soluzioni.

Su tutti i fogli che consegnerà, lo studente indichi il proprio cognome, nome e numero di matricola.
Nelle soluzioni non basta scrivere i risultati finali: riportare i passaggi principali e fornire adeguate spiegazioni.

©I diritti d'autore sono riservati. Ogni sfruttamento commerciale non autorizzato sarà perseguito.

Tempo: 2h 30min

Problema 1.

Iris lavora come biologa in un laboratorio di analisi ambientali. Ogni giorno esegue analisi su campioni d'acqua raccolti da laghi e fiumi della regione. Il tempo T (in ore) necessario per completare una singola analisi è una variabile aleatoria continua con densità:

$$f(x) = \begin{cases} \frac{1}{2}(\frac{5}{2} - x), & \text{se } 0 < x < a, \\ 0, & \text{altrimenti.} \end{cases}$$

(a) Determinare i valori di $a > 0$ per cui f è effettivamente una densità di probabilità. Tracciare un grafico qualitativo di f.

(b) Qual é la probabilità che una singola analisi duri esattamente mezz'ora? Qual è la probabilità che duri al più 15 minuti?

(c) Calcolare la media $\mathbb{E}[T]$ e la varianza $\mathrm{Var}(T)$.

(d) Iris deve eseguire 39 analisi. Sappiamo che le analisi effettuate su campioni diversi sono indipendenti fra loro. Definire il tempo totale S che Iris effettuerà per condurre le analisi in funzione dei tempi $T_1, T_2, \ldots, T_{39}$ delle singole analisi. Determinare approssimativamente la distribuzione di S, motivando adeguatamente la risposta.

(e) Calcolare, approssimativamente, la probabilità che Iris impieghi più di 18 ore per completare tutte le analisi.

Risultati.

(a) Affinchè f sia la densità di probabilità di una variabile aleatoria continua, devono valere due condizioni:

- Positività:

$$f(x) \geq 0 \quad \forall x \in (-\infty, +\infty) \quad \Rightarrow \quad \frac{1}{2}\left(\frac{5}{2} - x\right) \geq 0 \quad \text{per ogni } x \in (0, a) \quad \Rightarrow a \leq \frac{5}{2}.$$

- Normalizzazione:

$$\int_{-\infty}^{+\infty} f(x)\, dx = 1 \quad \Rightarrow \quad \int_0^a \frac{1}{2}\left(\frac{5}{2} - x\right) \mathrm{d}x = 1$$

Calcoliamo l'integrale:

$$\int_0^a \frac{1}{2}\left(\frac{5}{2} - x\right) \mathrm{d}x = \frac{1}{4}(5a - a^2)$$

Ponendo uguale a 1:

$$\frac{1}{4}(5a - a^2) = 1 \quad \Rightarrow \quad a^2 - 5a + 4 = 0$$

Risolvendo:

$$a \in \{1, 4\}.$$

Dato che dalla condizione di positività avevamo $a \leq \frac{5}{2}$, l'unico valore accettabile è $a = 1$. Pertanto

$$f(x) = \begin{cases} \frac{1}{2}(\frac{5}{2} - x), & \text{se } 0 < x < 1, \\ 0, & \text{altrimenti.} \end{cases}$$

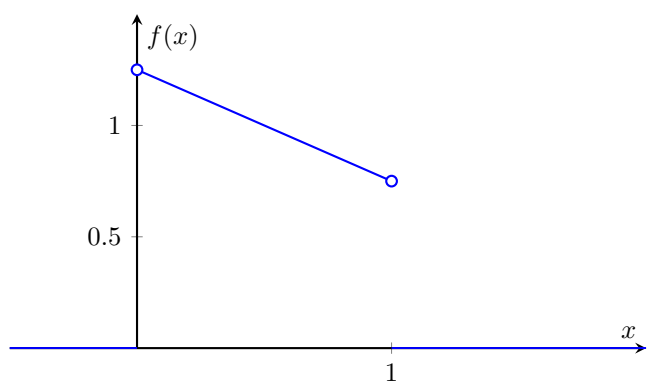

(b) Essendo T una variabile aleatoria continua si ha

$$\mathbb{P}(T = 0.5) = 0.$$

Infine,

$$\mathbb{P}(T \leq 0.25) = \int_0^{0.25} \frac{1}{2}\left(\frac{5}{2} - x\right) \mathrm{d}x \approx 0.296.$$

(c)

$$\mathbb{E}[T] = \int_{-\infty}^{+\infty} x f(x)\, \mathrm{d}x = \int_0^1 \frac{x}{2}\left(\frac{5}{2} - x\right) \mathrm{d}x = \left[\frac{5}{8}x^2 - \frac{1}{6}x^3\right]_{x=0}^{x=1} = \frac{11}{24} \approx 0.458.$$

$$\mathbb{E}[T^2] = \int_{-\infty}^{+\infty} x^2 f(x)\, \mathrm{d}x = \int_0^1 \frac{x^2}{2}\left(\frac{5}{2} - x\right) \mathrm{d}x = \left[\frac{5}{12}x^3 - \frac{1}{8}x^4\right]_{x=0}^{x=1} = \frac{7}{24} \approx 0.2917.$$

$$Var(T) = \mathbb{E}[T^2] - \mathbb{E}[T]^2 = \frac{47}{576} \approx 0.08159.$$

(d) Consideriamo la variabile aleatoria somma

$$S = \sum_{i=1}^{39} T_i.$$

Grazie al Teorema Centrale del Limite (TCL), applicabile perché $\{T_i\}_i \sim$ i.i.d. e $n = 39 > 30$, abbiamo:

$$S \approx \mathcal{N}\left(n\mathbb{E}[T], nVar(T)\right) = \mathcal{N}\left(39 \cdot \frac{11}{24},\ 39 \cdot \frac{47}{576}\right).$$

(e) Calcoliamo ora la probabilità che $S > 18$. Abbiamo

$$\mathbb{P}(S > 18) = \mathbb{P}\left(\frac{S - n\mathbb{E}[X]}{\sqrt{n\,\mathrm{Var}(X)}} > \frac{18 - 39 \cdot \frac{11}{24}}{\sqrt{39 \cdot \frac{47}{756}}}\right)$$

$$\approx 1 - \Phi\left(\frac{18 - 39 \cdot \frac{11}{24}}{\sqrt{39 \cdot \frac{47}{756}}}\right) = 1 - \Phi(0.08) \approx 1 - 0.53188 = 0.4682.$$

Problema 2.

Ogni giorno, sopra la città di Zenit, viene rilevato un numero di passaggi di satelliti artificiali. Questo numero è una variabile aleatoria distribuita secondo una Poisson con parametro λ. I passaggi di satelliti artificiali in giorni diversi sono indipendenti.

Ogni lunedì mattina, l'Osservatorio Astronomico Centrale pubblica un bollettino che riporta il numero totale di passaggi rilevati nella settimana precedente (cioè 7 giorni).

Siano X_1, X_2, X_3 i valori pubblicati nelle prossime tre settimane.

(a) Calcolate, in funzione di λ, il valore atteso e la varianza di una qualsiasi delle variabili aleatorie X_i, $i = 1, 2, 3$. Qual è la distribuzione di X_i, $i = 1, 2, 3$?

Tre giovani astrofili — Giorgio (G), Vittorio (V) e Francesco (F) — vogliono stimare il valore di λ. Propongono i seguenti stimatori:

$$T_{\mathrm{G}} = \frac{X_1 + X_2 + X_3}{3}, \quad T_{\mathrm{V}} = \frac{X_1 + X_2 + X_3}{21}, \quad T_{\mathrm{F}} = \frac{2X_1 - X_3}{7}.$$

(b) Calcolate la distorsione (bias) di ciascuno degli stimatori proposti per il parametro λ.

(c) Calcolate, in funzione di λ, l'errore quadratico medio (MSE) di ciascuno degli stimatori.

(d) Chi ha proposto lo stimatore migliore? E chi quello peggiore? Motivare la risposta.

(e) Sia p la probabilità che, in un giorno qualsiasi, si osservi almeno un passaggio di satellite. Calcolare p in funzione di λ.

(f) Costruire uno stimatore di p basato solo sulle variabili X_1, X_2, X_3.

Risultati.

(a) Se $Z_{i,j}$ è il numero di passaggi di satelliti artificiali nel j-esimo giorno dell'i-esima settimana, allora sappiamo dal testo che $Z_{i,j} \sim \mathcal{P}(\lambda)$ e che le v.a. $Z_{1,1}, \ldots, Z_{3,7}$ sono tutte indipendenti tra loro. Poiché

$$X_i = \sum_{j=1}^{7} Z_{i,j}\,,$$

dalla proprietà di riproducibilità della densità poissoniana segue che, per ogni $i = 1, 2, 3$,

$$X_i \sim \mathcal{P}(7\lambda)\,.$$

In particolare, per ogni $i = 1, 2, 3$,

$$\mathbb{E}\left[X_i\right] = \mathrm{Var}\left(X_i\right) = 7\lambda\,.$$

(b) Calcoliamo i valori attesi

$$\begin{aligned}
\mathbb{E}\left[T_G\right] &= \mathbb{E}\left[\frac{X_1 + X_2 + X_3}{3}\right] = \frac{1}{3}\left(\mathbb{E}\left[X_1\right] + \mathbb{E}\left[X_2\right] + \mathbb{E}\left[X_3\right]\right) = \frac{1}{3}\left(7\lambda + 7\lambda + 7\lambda\right) = 7\lambda\,,\\
\mathbb{E}\left[T_V\right] &= \mathbb{E}\left[\frac{X_1 + X_2 + X_3}{21}\right] = \frac{1}{21}\left(\mathbb{E}\left[X_1\right] + \mathbb{E}\left[X_2\right] + \mathbb{E}\left[X_3\right]\right) = \frac{1}{21}\left(7\lambda + 7\lambda + 7\lambda\right) = \lambda\,,\\
\mathbb{E}\left[T_F\right] &= \mathbb{E}\left[\frac{2X_1 - X_3}{7}\right] = \frac{1}{7}\left(2\mathbb{E}\left[X_1\right] - \mathbb{E}\left[X_3\right]\right) = \frac{1}{7}\left(14\lambda - 7\lambda\right) = \lambda\,.
\end{aligned}$$

Ne ricaviamo le distorsioni

$$\mathrm{bias}(T_k;\lambda) = \mathbb{E}\left[T_k\right] - \lambda = \begin{cases} 7\lambda - \lambda = 6\lambda & \text{per } k = \text{Giorgio} \\ \lambda - \lambda = 0 & \text{per } k = \text{Vittorio} \\ \lambda - \lambda = 0 & \text{per } k = \text{Francesco} \end{cases}.$$

(c) Usiamo la formula

$$\mathrm{mse}(T_k;\lambda) = \mathrm{Var}\left(T_k\right) + \mathrm{bias}(T_k;\lambda)^2$$

e calcoliamo dunque le varianze

$$\begin{aligned}
\mathrm{Var}\left(T_{\mathrm{G}}\right) &= \mathrm{Var}\left(\frac{X_1 + X_2 + X_3}{3}\right) = \left(\frac{1}{3}\right)^2 \left(\mathrm{Var}\left(X_1\right) + \mathrm{Var}\left(X_2\right) + \mathrm{Var}\left(X_3\right)\right)\\
&= \frac{1}{3^2}\left(7\lambda + 7\lambda + 7\lambda\right) = \frac{7}{3}\,\lambda\,,\\
\mathrm{Var}\left(T_{\mathrm{V}}\right) &= \mathrm{Var}\left(\frac{X_1 + X_2 + X_3}{21}\right) = \left(\frac{1}{21}\right)^2 \left(\mathrm{Var}\left(X_1\right) + \mathrm{Var}\left(X_2\right) + \mathrm{Var}\left(X_3\right)\right)\\
&= \frac{1}{21^2}\left(7\lambda + 7\lambda + 7\lambda\right) = \frac{1}{21}\,\lambda\,,\\
\mathrm{Var}\left(T_{\mathrm{F}}\right) &= \mathrm{Var}\left(\frac{2X_1 - X_3}{7}\right) = \left(\frac{1}{7}\right)^2 \left(4\mathrm{Var}\left(X_1\right) + (-1)^2\mathrm{Var}\left(X_3\right)\right)\\
&= \frac{1}{7^2}\left(28\lambda + 7\lambda\right) = \frac{5}{7}\,\lambda\,.
\end{aligned}$$

Si ottiene

$$\mathrm{mse}(T_k;\lambda) = \begin{cases} (7/3)\,\lambda + 36\,\lambda^2 & \text{per } k = \text{Giorgio} \\ (1/21)\,\lambda & \text{per } k = \text{Vittorio} \\ (5/7)\,\lambda & \text{per } k = \text{Francesco} \end{cases}.$$

(d) T_{V} e T_{F} sono stimatori non distorti per il parametro λ, mentre T_{G} è distorto. Inoltre,

$$\mathrm{mse}(T_{\mathrm{V}};\lambda) < \mathrm{mse}(T_{\mathrm{F}};\lambda) < \mathrm{mse}(T_{\mathrm{G}};\lambda)\,.$$

Dunque, lo stimatore migliore è quello proposto da Vittorio, che è non distorto e ha l'mse minore. Il peggiore, invece, è quello di Giorgio, che è distorto e ha l'mse più grande.

(e) Se Z è il numero di satelliti che passano in un giorno, sappiamo che $Z \sim \mathcal{P}(\lambda)$, e

$$p = \mathbb{P}\left(Z > 0\right) = 1 - \mathbb{P}\left(Z = 0\right) = 1 - p_Z(0) = 1 - \mathrm{e}^{-\lambda}\,.$$

(f) Essendo T_V lo stimatore migliore di λ, come stimatore di p possiamo considerare

$$\hat{p} = 1 - \mathrm{e}^{-T_{\mathrm{V}}}\,.$$

Problema 3. Un laboratorio di ingegneria dei materiali sta sperimentando una nuova lega metallica da utilizzare nella produzione di componenti per motori elettrici. Una delle caratteristiche critiche è il tempo di raffreddamento X (in minuti) dopo il processo di fusione.

Per valutare il comportamento termico della lega, sono stati misurati i tempi di raffreddamento in 10 campioni:

$$15,\ 18,\ 20,\ 16,\ 18,\ 22,\ 17,\ 14,\ 21,\ 19$$

(a) Calcolare la media campionaria e la deviazione standard campionaria dei tempi di raffreddamento.

(b) Determinare l'intervallo di confidenza al 95% a due code per la media del tempo di raffreddamento. Che ipotesi è necessario fare sul campione per rispondere a questa domanda?

(c) L'azienda dichiara che la lega si raffredda in meno di 20 minuti in media. Verificare questa affermazione mediante un test di ipotesi con livello di significatività del 5%. Che ipotesi è necessario fare sul campione per rispondere a questa domanda?

[*Specificare: test, ipotesi, statistica-test, regione critica, decisione*].

(d) In un test industriale su 100 pezzi, si è osservato che per 80 di essi il tempo di raffreddamento è stato al massimo 20 minuti. L'azienda sostiene che almeno la metà dei pezzi prodotti rispetta questa soglia.
Verificare questa affermazione usando un test di ipotesi appropriato con un livello di significatività approssimato pari al 5%.

[*Specificare: test, ipotesi, statistica-test, regione critica, decisione*].

(e) Calcolare il p-value del test al punto (d) e discutere come cambierebbe la decisione con un livello di significatività dell'1%.

Risultati.

(a) La stima puntuale della media campionaria $\overline{X}$ con i dati a disposizione vale:

$$\overline{x} = \frac{1}{10}\sum_{i=1}^{10} x_i = 18.0 \text{ min}\,.$$

Inoltre, la stima puntuale della varianza campionaria S^2 con i dati a disposizione vale:

$$s^2 = \frac{1}{10-1}\sum_{i=1}^{10}(x_i - \overline{x})^2 = \frac{1}{9}\left(\sum_{i=1}^{10} x_i^2 - 10\overline{x}^2\right) = \frac{1}{9}(3\,300 - 3\,240) = 6.\overline{6} \simeq 6.6667 \text{ min}^2\,,$$

da cui segue che $s \simeq 2.5820$ min.

(b) Vista la poca numerosità de dati a disposizione, dobbiamo lavorare sotto l'ipotesi di gaussianità dei dati. Si tratta di calcolare:

$\text{IC}_{1-\alpha}(\mu)$ per $\mathcal{N}(\mu, \sigma^2)$, due code, σ incognita: $\overline{X} - \frac{S}{\sqrt{n}} t_{1-\alpha/2}(n-1) \leq \mu \leq \overline{X} + \frac{S}{\sqrt{n}} t_{1-\alpha/2}(n-1)\,.$

In questo caso, si ottiene:

$$18.0 - \frac{2.5820}{\sqrt{10}} t_{0.975}(9) \leq \mu \leq 18.0 + \frac{2.5820}{\sqrt{10}} t_{0.975}(9) \quad \Longrightarrow \quad 16.1530 \text{ min} \leq \mu \leq 19.8470 \text{ min}\,,$$

essendo $t_{0.975}(9) = 2.2622$.

(c) Si tratta di effettuare il test per la media di una popolazione normale $X \sim \mathcal{N}(\mu, \sigma^2)$, σ incognita. Le ipotesi del test sono $H_0 : \mu \geq \mu_0$ vs. $H_1 : \mu < \mu_0$, dove $\mu_0 = 20.0$ min

La statistica test da considerare è $U = \dfrac{\overline{X} - \mu_0}{S/\sqrt{n}}$ e la regione critica è della forma $U \leq -t_{1-\alpha}(n-1)$, dove $\alpha = 0.05$. Il valore osservato sulla base dei dati a disposizione è $u^* = \dfrac{18.0 - 20.0}{2.5820/\sqrt{10}} \simeq -2.4495$

Dato che $-2.4495 < -t_{0.95}(10-1) \simeq -1.8331$ si rifiuta H_0 al 5%. C'è evidenza statistica per affermare che l'azienda dichiari il vero, ossia che i tempi di raffreddamento della lega metallica siano inferiori a 20.0 minuti.

(d) Sia Y la variabile aleatoria con distribuzione di Bernoulli, per cui si registra il successo ($Y = 1$) se il tempo di raffreddamento della lega metallica è al massimo pari a 20 minuti ($X \leq 20$ min). Innanzitutto si calcola la proporzione campionaria, cioè la percentuale di successi nel campione a disposizione. Dal momento che per 80 pezzi su 100, il tempo di raffreddamento è minore o uguale a 20 minuti, allora segue che $\hat{p} = 80/100 = 0.8$. Ora si tratta di effettuare il test per la proporzione di una popolazione Bernoulliana $Y \sim \text{Be}(p)$. Le ipotesi del test sono: $H_0 : p < p_0$ vs. $H_1 : p \geq p_0$, dove $p_0 = 0.5$. La statistica test da considerare è $U = \dfrac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$ e la regione critica è della forma $U \geq z_{1-\alpha}$, dove $\alpha = 0.05$. Il valore osservato sulla base dei dati raccolti è pari a $u^* = \dfrac{0.8 - 0.5}{\sqrt{\frac{0.5(1-0.5)}{100}}} \simeq 6$. Dato che $6 > z_{0.95} = 1.645$ si rifiuta H_0 al 5%. C'è evidenza statistica per affermare che i tempi di raffreddamento dichiarati dall'azienda siano rispettati per almeno un pezzo su due.

(e) Il valore del p-value risulta essere pari a $1 - \Phi(u^*) \simeq 1 - \Phi(6) \simeq 0$. Quindi, si rifiuta l'ipotesi nulla all'1% (e al 5%).